



## Какой экзогенный фактор является информативным при прогнозировании европейской углеродной волатильности: облигации, товары, акции или неопределенность?

Jiqian Wang<sup>a,b</sup>, Xiaozhu Guo<sup>a</sup>, Xueping Tan<sup>c,d</sup>, Жюльен Шевалье<sup>e,f</sup>, Фэн Ма<sup>a,b,\*</sup>

<sup>a</sup> Школа экономики и менеджмента, Юго-Западный университет Цзяотун, Чэнду, Китай

<sup>b</sup> Ключевая лаборатория науки и инноваций в сфере услуг провинции Сычуань

<sup>c</sup> Школа экологических наук и инженерии, Шанхайский университет Цзяо Тун, Шанхай, Китай

<sup>d</sup> Школа экономики и менеджмента, Китайский университет горного дела и технологий, Сюйчжоу, Китай

<sup>e</sup> Бизнес-школа IPAG (Лаборатория IPAG), 184 bd Saint-Germain, 75006 Париж, Франция

<sup>f</sup> Университет Париж 8 (LED), 2 улица Свободы, 93526 Сен-Дени, Франция



### А Р Т И К Л И Я В Ф О

#### Ключевые слова:

Европейский углеродный рынок Прогнозирование волатильности  
Экзогенный драйвер  
Метод супервизорного обучения

### А Б С Т Р А К Т

Данное исследование опирается на 45 экзогенных факторов для повышения точности прогнозирования волатильности EUA. Несколько популярных линейных и нелинейных прогнозных регрессий, включая индивидуальный факторный анализ, метод комбинированного прогнозирования, модель диффузионного индекса и метод контролируемого обучения, используются для составления прогнозов волатильности на ежемесячной частоте. Наши эмпирические результаты показывают, что модель диффузионного индекса и комбинированный метод прогнозирования не могут управлять волатильностью EUA в богатом данными мире из-за худшей эффективности прогнозирования отдельных факторов; однако метод контролируемого обучения может успешно прогнозировать волатильность EUA. Кроме того, индекс глобальных инноваций WilderHill new energy, спред доходности корпоративных облигаций еврозоны, индекс золота GSCI и спред доходности государственных облигаций еврозоны могут чрезвычайно сильно влиять на волатильность EUA с точки зрения анализа отдельных факторов, частоты выбора переменных и важности факторов. Наши результаты дают важные выводы для участников рынка и эмиссионных компаний, которые должны уделять больше внимания движению цен на европейском рынке облигаций, золота и чистой энергии.

## 1. Введение

Система торговли выбросами Европейского союза (EU ETS) является первым в мире рынком торговли углеродными квотами и направлена на снижение выбросов углерода (Alberola et al., 2008; Chevallier, 2009). Разрешения Европейского союза (EUA) представляют собой разрешения на выбросы углерода и могут продаваться напрямую. В частности, если выбросы CO<sub>2</sub> фирмы превышают (меньше, чем) ее квоты, она может купить (продать) большее (избыточное) их количество. С момента появления фьючерсного контракта EUA волатильность EUA в последнее время привлекает все больше внимания со стороны научных кругов, углеродоемких компаний и правительства. Точное прогнозирование волатильности EUA может помочь инвесторам или компаниям, занимающимся выбросами, экономически выгодно использовать стратегии рыночного тайминга для покупки или продажи разрешений на выбросы и помочь регулирующим органам эффективно направлять развитие углеродного рынка. Поэтому

Для инвесторов и менеджеров значительно привлекательным является выявление предиктивных факторов, так как это позволит в дальнейшем выявить динамику волатильности углерода. Данное исследование в основном проливает свет на информационное содержание 45 экзогенных факторов, включая 8 факторов, связанных с облигациями, 12 факторов, связанных с товарами, 11 факторов, связанных с акциями, и 14 факторов, связанных с неопределенностью, используя методы комбинированного прогнозирования, диффузного индексирования и контролируемого обучения.

Существующие исследования зафиксировали, что большой набор экзогенных переменных может определять волатильность европейского углеродного рынка (см., например, Chevallier, 2010; Byun and Cho, 2013; Dutta, 2018; Dai et al., 2022; Liu et al., 2021) или цены углеродных квот (см., например, Paoletta and Taschini, 2008; Chevallier, 2011c; Fan et al., 2017; Tan et al., 2021; Ren et al., 2022a, 2022b; Wen et al., 2022). Кроме того, многочисленные исследования посвящены связи или побочному эффекту между углеродными квотами и другими рынками, например, фундаментальным рыночным показателям (Christiansen et al., 2005),

---

\* Автор-корреспондент: Школа экономики и менеджмента, Юго-Западный университет Цзяотун, Китай.

Адреса электронной почты: [wangjiqian@my.swjtu.edu.cn](mailto:wangjiqian@my.swjtu.edu.cn) (J. Wang), [xp\\_flistars19@cumt.edu.cn](mailto:xp_flistars19@cumt.edu.cn) (X. Tan), [julien.chevallier@ipag.fr](mailto:julien.chevallier@ipag.fr) (J. Chevallier), [mafeng2016@swjtu.edu.cn](mailto:mafeng2016@swjtu.edu.cn) (F. Ma).

<sup>1</sup> В литературе используются различные эконометрические и статистические модели для исследования цен на углерод, доходности и волатильности, такие как модели типа GARCH (Chevallier, 2009; Feng et al., 2011; Byun and Cho, 2013; Dutta, 2018; Liu et al., 2021), модель HAR-RV (Chevallier and S'evì, 2011) и методы машинного обучения (Zhu et al., 2018).

<https://doi.org/10.1016/j.eneco.2022.106419>

Получено 15 апреля 2022 г.; Получено в исправленном виде 7 ноября 2022 г.; Принято 14 ноября 2022 г.

Доступно онлайн 23 ноября 2022 года

0140-9883/© 2022 Elsevier B.V. Все права защищены.

рынки ископаемых энергоносителей (Zhang and Sun, 2016), рынки чистой энергии (Dutta et al., 2018), неэнергетические рынки (Tan et al., 2020), рынки акций (Chevallier, 2009) и неопределенность рынка (Ye et al., 2021; Wen et al., 2022). Несомненно, точное моделирование волатильности углерода играет жизненно важную роль в распознавании динамики цен на углерод и контроле рыночного риска. Однако на практике инвесторам и участникам рынка крайне сложно точно прогнозировать ее, поскольку динамика волатильности углеродных квот легко нарушает структуру, обусловленную регулированием EU ETS.

Мотивированное предыдущими исследованиями европейского углеродного рынка, наше исследование направлено на решение

трех вопросов, чтобы расширить литературу по прогнозированию волатильности EUA. Во-первых, какой экзогенный предиктор может в большей степени влиять на волатильность EUA? Согласно аргументам Бенца и Трюка (2009), цена на углерод напрямую определяется спросом и предложением углеродных квот.<sup>2</sup> В связи с этим существующие исследования показали корреляцию между ценой углеродных квот и де-факто факторами, включая погоду (Mansanet-Bataller et al., 2007), макроэкономику (Chevallier, 2011c), сырую нефть (Byun and Cho, 2013), газ (Wang and Guo, 2018), уголь (Byun and Cho, 2013), электричество (Aatola et al., 2013), неэнергетические товары (Tan et al., 2020), акции (Dutta et al., 2018), облигации (Chevallier, 2010; Ren et al., 2022b) и неопределенность экономической политики (Dai et al., 2022). В частности, Byun и Cho (2013) исследуют способность к прогнозированию нефти марки Brent, угля и электрического природного газа и утверждают, что волатильность энергоносителей может повысить эффективность прогнозирования. Однако предыдущие исследования, например, Byun и Cho (2013), Tan и др. (2020), Dai и др. (2022) и другие, обычно фокусируются на прогнозировании по факторам одного класса (энергетические, финансовые, факторы неопределенности), и лишь немногие исследования изучают прогнозирование волатильности углерода с помощью большого набора предикторов. Хорошо известно, что чем больше категорий предикторов, тем больше прогностической информации. Поэтому, чтобы восполнить этот пробел, в нашем исследовании рассматриваются 45 экзогенных факторов, чтобы изучить их эффективность прогнозирования и выяснить, какой предиктор может эффективно управлять волатильностью EUA.

Во-вторых, как инвесторы и исследователи используют информацию, извлеченную из

различные предикторы на практике? В условиях насыщенной данными среды участники рынка могут получать огромное количество информации из Интернета, социальных сетей и других каналов. Однако инвесторы не могут рассмотреть всю информацию из-за ограниченного внимания инвесторов. В существующих исследованиях регулярно применяются методы уменьшения размерности для извлечения полной информации из большого количества предикторов и избежания проблем перебора (Neely et al., 2014; Huang et al., 2015; Zhang et al., 2019; Huang et al., 2021; Wang et al., 2022; Zhang et al., 2022). В частности, Ванг и др. (2022) используют анализ главных компонент (PCA), регрессию частичных наименьших квадратов (PLS) и масштабированный PCA (SPCA) для извлечения общей информации из глобальных экономических условий и индексов неопределенности на основе новостей для прогнозирования реализованной дисперсии волатильности акций природного газа и чистой энергии. В соответствии с предыдущей литературой по прогнозированию волатильности, наше исследование разрабатывает индекс диффузии из моделей PCA, PLS и SPCA для изучения их информационного содержания прогноза волатильности EUA. Кроме того, комбинирование прогнозов является еще одним популярным методом включения информации от значительных переменных (Rapach et al., 2010; Zhang et al., 2019; Wang et al., 2022). В связи с этим мы также

рассматриваем три популярных метода комбинирования, то есть средние комбинированные прогнозы (MCF), медианные комбинированные прогнозы (MECF) и обрезанные комбинированные прогнозы (TCF), для включения информации и преодоления неопределенности модели (Rapach et al., 2010).

В-третьих, помогает ли метод контролируемого обучения повысить точность

прогнозирования волатильности EUA? Сложные характеристики волатильности EUA, такие как высокая волатильность, нелинейная динамика и нестабильность (Alberola et al., 2008; Chevallier, 2011a, 2011b; Feng et al., 2011), которые приводят к

<sup>2</sup> Регулирование и политика EU ETS всегда классифицируются как фактор предложения углеродных квот. В нашем исследовании мы в основном фокусируемся на экзогенных факторах спроса на углеродные квоты, поскольку фактор предложения трудно поддается количественной оценке.

Точное прогнозирование и моделирование волатильности углерода остается сложной задачей. Регрессия OLS является преобладающим инструментом для прогнозирования временных рядов, но Bishop и Nasrabadi (2006) утверждают, что ее эффективность низка, когда в регрессии существует много потенциальных объясняющих переменных. Однако алгоритм машинного обучения может игнорировать ограничение числа объясняющих переменных, что предоставляет новые возможности участникам рынка и исследователям для прогнозирования цены или волатильности в энергетических финансах (Ghoddusi et al., 2019). Три популярных метода контролируемого обучения, которые широко используются на финансовых рынках, применяются для изучения их эффективности на европейском углеродном рынке, включая оператор наименьшего абсолютного сокращения и выбора (LASSO) Тибишир-ани (1996), эластичную сеть (ELN) Зоу и Хасты (2005) и опорную векторную регрессию (SVR) Вапника (1999). LASSO и ELN опираются на штрафную функцию для выбора влиятельных факторов и минимизации ошибки суммы квадратов, тем самым повышая точность прогнозирования волатильности (Zhang et al., 2019; Plakandaras and Ji, 2022; Wang et al., 2022). Профессор Вапник впервые предложил машину опорных векторов (SVM) для решения проблем классификации; позже, основываясь на SVM, Вапник (1999) разработал SVR для решения проблем подгонки функций. SVR опирается на принцип минимизации структурного риска, в результате чего этот метод сталкивается с небольшими выборками и преодолевает проблемы локального оптимального решения, что является одним из основных преимуществ (Awad and Khanna, 2015).

Для измерения волатильности европейского углеродного рынка существующие исследования предпочитают модели типа GARCH (Chevallier, 2009; Feng et al., 2011; Byun and Cho, 2013; Dutta, 2018; Liu et al., 2021); однако реализованная волатильность (RV) широко используется в области прогнозирования волатильности из-за ее очевидных преимуществ, таких как меньший макроэкономический шум и простота реализации (Corsi, 2009; Chevallier and S'evi, 2011; Wang et al., 2022; Zhang et al., 2022). Кроме того, Chevallier и S'evi (2011) утверждают, что модель HAR-RV Корси (2009) превосходит модель GARCH в прогнозировании волатильности EUA. Учитывая частоту данных макроэкономических переменных и различных индексов неопределенности (в основном, ежемесячно или ежеквартально), следуя направлениям литературы по прогнозированию финансовой волатильности (например, Paye, 2012; Wang and Guo, 2018; Wang et al., 2022; Zhang et al., 2022), наше исследование использует реализованную волатильность на ежемесячной частоте для моделирования волатильности на европейском рынке выбросов углерода.

Мы рассматриваем следующие 4 группы экзогенных факторов волатильности EUA, которые были включены в работы Chevallier (2011a), Byun and Cho (2013), Tan et al. (2021), Ren et al. (2022a), Wen et al. (2022) и другие: 1) факторы, связанные с товарами (энергоносители и металлы); 2) факторы, связанные с облигациями; 3) факторы, связанные с акциями; и 4) факторы, связанные с неопределенностью. Эти 45 экзогенных факторов волатильности углерода определяются следующей потенциальной теоретической иллюстрацией. Во-первых, несомненно, факторы, связанные с энергетикой, могут напрямую влиять на цены на углерод через потребление энергии и выбросы, в то время как факторы, связанные с металлами, могут также определять волатильность выбросов углерода через стоимость материалов, производство и транспортировку (Chevallier, 2009). Во-вторых, спред доходности облигаций и безрисковая доходность всегда могут отражать внутренние экономические условия. В частности, в период экологического процветания доходность облигаций будет ниже, в то время как выбросы углекислого газа будут увеличиваться из-за роста производственной деятельности и потребления энергии. В-третьих, финансовая деятельность может влиять на волатильность цен на углерод через затраты на финансирование

соответствующих корпоративных ставок энергии и моделизацию технологий. В нашем исследовании мы рассматриваем индексы фондовых рынков 11 промышленных стран мира для оценки финансовой деятельности. Наконец, факторы, связанные с неопределенностью, состоят из следующих частей: 1) глобальный индекс новой энергии; 2) подразумеваемая волатильность индекса S&P 500 и сырой нефти WTI; 3) индекс неопределенности политики в глобальном и европейском регионах на основе новостей; и 4) индекс неопределенности климата на основе новостей. Более подробную информацию можно найти в разделе 3. Эмпирически мы получили следующие результаты. Во-первых, индекс глобальных инноваций в новой энергетике (NEGI), спред доходности корпоративных облигаций Еврозоны (ECBRS), индекс золота GSCI (GDI) и спред доходности государственных облигаций Еврозоны (EGYS) могут определять волатильность EUA с точки зрения индивидуального факторного анализа, частоты выбора переменных и факторов.

важность. Во-вторых, модель индекса диффузии (PCA, PLS и SPCA) и метод комбинированного прогнозирования (MCF, MECF и TCMF) практически не улучшают точность прогнозирования волатильности на европейском углеродном рынке, поскольку большинство отдельных предикторов показывают ограниченную эффективность прогнозирования. В-третьих, интерес представляет метод контролируемого обучения (ELN, LASSO и SVR), который благодаря своим преимуществам может существенно предсказать волатильность EUA. В частности, выбор переменных (ELN и LASSO) позволяет достичь компромисса между смещением и дисперсией, а SVR лучше подходит для небольших выборок, нелинейных характеристик и высокоразмерной регрессии, что приводит к повышению эффективности прогнозирования. Наконец, результаты Анализ экономической стоимости показывает, что метод контролируемого обучения

может получить более высокую реализованную полезность, чем конкурирующие модели.

Наше исследование вносит вклад в литературу по моделированию и прогнозированию волатильности EUA тремя способами. Во-первых, в отличие от предыдущих исследований (таких как Chevallier, 2009; Feng et al., 2011; Byun and Cho, 2013; Dutta, 2018; Liu et al., 2021), мы строим реализованную волатильность EUA на ежемесячной частоте и вводим некоторые преобладающие модели временных рядов для построения прогнозов волатильности, что дает новое понимание для прогнозирования волатильности EUA. Во-вторых, многочисленные исследования посвящены предиктивности будущих цен на EUA (например, Byun and Cho, 2013; Dutta, 2018; Dai et al., 2022; Liu et al., 2021), и наше исследование расширяет их работу, изучая вопрос о том.

45 экзогенных факторов могут в большей степени влиять на волатильность EUA. Точное прогнозирование волатильности выгодно для инвесторов и эмиссии компаний в диверсификации портфеля, ценообразовании деривативов, хеджировании и управлении финансовыми рисками. В-третьих, многие влиятельные исследования, например, Rapach и др. (2010), Neely и др. (2014), Zhang и др. (2019), Huang и др. (2021), утверждают, что комбинированный метод прогнозирования (MCF, MECF и TCMF) и модель диффузионного индекса (PCA, PLS и SPCA) могут успешно прогнозировать доходность или волатильность активов. Мы представляем предыдущие методы и исследуем, могут ли комбинированный метод прогнозирования и диффузионный индекс

модель может помочь повысить точность прогнозирования волатильности EUA.

Кроме того, в дополнение к методу комбинированного прогнозирования и

Модель индекса диффузии, мы эмпирически исследуем способность к прогнозированию методов контролируемого обучения (ELN, LASSO и SVR) в соответствии с быстрым развитием методов машинного обучения в энергетических финансах (Ghoddusi et al., 2019). Насколько нам известно, наше исследование является первым, в котором сравниваются вышеупомянутые прогностические регрессии, которые широко используются в литературе по прогнозированию волатильности энергоносителей и могут предложить более полное понимание для точного прогнозирования волатильности в условиях богатой методами среды на рынке фьючерсов EUA.

Остальная часть статьи организована следующим образом. В разделе 2 представлена методология. В разделе 3 описывается набор данных по волатильности EUA и 45 экзогенных факторов. В разделе 4 представлен эмпирический анализ. Заключительные замечания приведены в разделе 5.

## 2. Методология

оптимального порядка лага  $p$ , в отличие от Chevallier и S'evi (2011), мы рассматриваем информационный критерий AIC. Результаты показывают, что оптимальное значение  $p$  равно 2.

Чтобы изучить, какие индивидуальные предикторы могут успешно определять волатильность цен на углерод, мы расширили модель (1) 45 экзогенными переменными, определенными как

$$RV_{t+1} = \beta_0 + \sum_{i=1}^p \beta_i RV_{t-i+1} + \varphi_{\alpha} X_{t,\alpha} + \varepsilon_{t+1}, \quad (2)$$

где  $X_{t,\alpha}$  обозначает переменную  $\alpha^{\text{th}}$  в месяце  $t$ , а регрессия  $\varphi_{\alpha}$

коэффициент для переменной  $\alpha^{\text{th}}$ .

### 2.2. Комбинированный метод прогнозирования

Вдохновленный Rapach et al. (2010), метод комбинированного прогнозирования может включать информацию от различных предикторов и избегать неопределенности модели. В соответствии с предыдущими исследованиями прогнозирования волатильности, мы применяем три метода комбинированного прогнозирования, которые можно определить как

$$RV_{c,t+1} = \sum_{i=1}^N \hat{\omega}_{i,t} RV_{i,t+1}, \quad (3)$$

где  $\{\hat{\omega}_{i,t}\}_{i=1}^N$  обозначает предварительный комбинированный вес  $N$  индивидуумов

прогнозы, сформированные в месяце  $t$ .  $RV_{i,t+1}$  - прогнозы волатильности, сформированные в месяце  $t$ . из уравнения (2), а  $RV_{c,t+1}$  представляет собой комбинацию прогнозов. Мы рассматриваем простые усредненные методы комбинирования, включая среднее значение, медиана и обрезанное среднее. В частности, средняя комбинация прогнозов (MCF) задается  $\omega_{i,t} = 1/N$  в уравнении (3), медианная комбинация прогнозирует  $\left\{ \right\}$  (MECF) развиваются по медиане  $\{RV_{i,t+1}\}_{i=1}^N$ , и обрезанный ком-

### 2.1. Эталонная модель

Существующие исследования рассматривают модель типа GARCH для измерения волатильности углерода (Chevallier, 2009; Feng et al., 2011; Byun and Cho,

бинарные прогнозы (TMCF) устанавливают  $\omega_{i,t} = 0$  для наибольшего и наименьшего значений  $N$  индивидуальных прогнозов и  $\omega_{i,t} = 1/(N - 2)$  для остальных прогнозов в уравнении (3).

### 2.3. Модель диффузионного индекса

Модель диффузионного индекса направлена на извлечение комплексной информации из различных предикторов и преодоление проблем переборки и широко используется в области прогнозирования на финансовых рынках (Neely et al., 2014; Zhang et al., 2019; Huang et al., 2021; Wang et al., 2022;

2013; Dutta, 2018; Liu et al., 2021). Тем не менее, Шевалье и Сэни (2011) утверждают, что модель HAR-RV Корси (2009) работает лучше, чем модель GARCH при прогнозировании волатильности ECA. Поэтому в нашем исследовании для моделирования волатильности цен на углерод используется реализованная волатильность (RV). Более того, Корси (2009) указывает, что модель HAR-RV может быть упрощена как модель авторегрессии (AR (22)), которая широко используется в области прогнозирования и может быть непосредственно определена как

$$RV_{t+1} = \beta_0 + \sum_{i=1}^p \beta_i RV_{t-i+1} + \varepsilon_{t+1}, \quad (1)$$

где RV обозначает реализованную волатильность на месячной частоте,

выраженная как сумма ежедневных квадратов  $\sum_{j=1}^M r_{t,j}^2$ , где  $M$  это количество торговых дней для конкретного месяца  $t$ , а  $r_{t,j}$  представляет собой

доходность  $j$ -го дня месяца  $t$ .  $\varepsilon_{t+1}$  - член возмущения. Для получения

Zhang et al., 2022). Рассматриваемые нами модели (индекса диффузии) различаются по способу извлечения полной информации и могут быть организованы в следующие два класса:

Во-первых, мы рассматриваем главный компонент, извлеченный из предикторов, связанных с облигациями, предикторов, связанных с товарами, предикторов, связанных с акциями, предикторов, связанных с неопределенностью, и всех предикторов. В частности, регрессия с индексом диффузии, извлеченным из модели анализа главных компонент (PCA), может быть записана как

$$RV_{t+1} = \beta_0 + \sum_{i=1}^p \beta_i RV_{t-i+1} + \sum_{k=1}^K \gamma_k F_k^{PCA} + \varepsilon_{t+1}, \quad (4)$$

где  $F_k^{PCA}$  обозначает главную компоненту, извлеченную из  $X_{i,t}$ . Для выбора  $K$  и в соответствии с Neely et al. (2014) мы использовали  $adjusted R^2$ .

Недавно Хуанг и др. (2021) модифицировали модель PCA с точки зрения масштабирования каждой переменной по ее коэффициентам из следующей регрессии:  $RV_{t+1} = \alpha_i + \beta X_{i,t} + \varepsilon_{t+1}$ , где  $\beta_i$  - масштабированный коэффициент. Подсе- Затем мы проводим PCA на  $\{\beta X_{11,t}, \beta X_{22,t}, \dots, \beta X_{i,t}\}$  для

индекс диффузии, специфичный для конкретной цели. В частности, модель масштабирования-PCA (SPCA) может быть записана как

$$RV_{t+1} = \beta_0 + \sum_{i=1}^p \beta_i RV_{t-i+1} + \sum_{k=1}^K \sum_{i=1}^p \gamma_{ki} F_i^{SPCA} + \varepsilon_{t+1}, \quad (5)$$

где оптимальное  $K$  определяется скорректированным  $R^2$ .



Во-вторых, [Хуанг и др. \(2015\)](#) утверждают, что модель частичных наименьших квадратов (PLS) также может успешно построить комплексную информацию от различных факторов. В частности, регрессия  $N$  временных рядов индивидуального предиктора ( $\mathbf{X}_{i,t}$ ) и волатильности EUA ( $\mathbf{X}_{i,t} = \alpha_{i,0} + \alpha RV_{i,t-1} + \varepsilon_{i,t}$ ) используется для получения расчетного коэффициента, . Индекс диффузии модели PLS ( $F^{PLS}$ ), полученный из различных предикторов, может быть определен как

$$X_{i,t} = \varphi_{i,0} F^{PLS}_{ai} + \varepsilon_{i,t}, \quad (6)$$

где оцененный коэффициент  $\alpha_i$  обозначает индекс диффузии PLS. PLS можно представить в виде

$$RV_t = \beta + \sum_{i=1}^p \beta_i RV_{i,t} + \beta F^{PLS} + \varepsilon_t. \quad (7)$$

#### 2.4. Методы контролируемого обучения

В последние годы быстрое развитие методов машинного обучения открыло новые возможности в области финансирования энергетики ([Ghoddusi et al., 2019](#)). В соответствии с различиями в алгоритмах мы разделили три метода контролируемого обучения, рассмотренные в данном исследовании, на два набора.

Во-первых, отбор переменных, такой как LASSO и ELN, является одним из самых популярных методов контролируемого обучения в литературе по прогнозированию ([Zhang et al., 2019](#); [Wang et al., 2022](#); [Zhang et al., 2022](#)). Выбор переменных опирается на штрафную функцию, которая может установить коэффициенты неважных переменных на (к) нулю для достижения сокращения размерности.

В частности, результаты коэффициентов, оцененные с помощью LASSO ( $\beta_{LASSO}$ ) и ELN ( $\beta_{EN}$ ), могут быть выражены как

$$\beta_{LASSO} = \underset{\beta}{\operatorname{argmin}} \left( \frac{1}{2(t-1)} \sum_{i=1}^{t-1} (RV_{i+1} - \beta_0 - \sum_{i=1}^p \beta_i X_{i,t})^2 + \lambda \sum_{i=1}^p |\beta_i| \right), \quad (8)$$

$$\beta_{EN} = \underset{\beta}{\operatorname{argmin}} \left( \frac{1}{2(t-1)} \sum_{i=1}^{t-1} (RV_{i+1} - \beta_0 - \sum_{i=1}^p \beta_i X_{i,t})^2 + \lambda \sum_{i=1}^p ((1-\alpha)\beta^2 + \alpha|\beta|) \right), \quad (9)$$

где  $\lambda(\alpha)$  - настроенный параметр, который может управлять усачочными эс- тиматорами с точки зрения строгости штрафов. Очевидно, что LASSO опирается только на штрафные функции  $L_1$  ( $\lambda$ ), в то время как ELN опирается на штрафные функции  $L_1$  и  $L_2$  ( $\lambda$  и  $\alpha$ ). В частности,  $\alpha$  - положительная константа ( $\alpha \in [0, 1]$ ); когда  $\alpha = 1$ , ELN точно такая же, как и LASSO. Для получения оптимального выбора  $\alpha$  и  $\lambda$  мы используем тот же алгоритм, что и [Zhang et al. \(2019\)](#), чтобы определить оптимальное значение до построения прогнозов волатильности.<sup>3</sup>

Во-вторых, [Ghoddusi et al. \(2019\)](#) рассматривают использование методов машинного обучения в энергетических финансах и обнаруживают, что машина опорных векторов является одним из самых популярных методов. Для построения прогнозов волатильности мы рассматриваем метод SVR, который быстрее обычных SVM в плане глобальных решений по различным линейным регрессиям ([Zhang and Zhang, 2018](#)). Математически предполагая, что набор обучающих точек  $\{(x_i, y_i)\}_{i=1}^n$  с входными данными

данные  $x_i^n \in R$  и выходные данные  $y_i \in R$ , функция принятия

$$\min_{z_i} \frac{1}{2} \|z_i\|^2 + \frac{c}{2} \sum_{i=1}^n \xi_i^2 \quad (11)$$

$$\text{s.t. } y_i = \omega^T \kappa(z_i) + \xi_i + b, \quad i \in [1, n],$$

где  $c$  - константа регуляризации, а  $\xi_i$  представляет собой тренировочное значение

ошибка. Для функции ядра SVR в данном исследовании мы рассматриваем радиальную базисную функцию (RBF) в соответствии с [Zhang и Zhang \(2018\)](#).

### 3. Данные

#### 3.1. Серия цен на углерод

Для измерения цен на углерод мы рассматриваем непрерывную расчетную цену ICE ECX EUA (обозначается EUA), которая имеет наиболее ликвидные фьючерсные контракты на рынке торговли выбросами углерода. Мы собираем ежедневную цену закрытия EUA из базы данных WIND, чтобы построить временной ряд RV с ежемесячной частотой с июля 2008 года по октябрь 2021 года, содержащий 160 месяцев. Этот период расширяет период выборки [Тан и др. \(2021\)](#), и, как и в многочисленных исследованиях EUA, мы пренебрегаем Фазой I Системы торговли выбросами Европейского союза, поскольку движение цен в этот период было в основном обусловлено изменениями в законодательстве и политике.

#### 3.2. Предикторы

Вслед за существующими исследованиями в области моделирования цены или волатильности

EUA, такие как [Chevallier \(2011a\)](#), [Byun and Cho \(2013\)](#), [Tan et al. \(2021\)](#), [Ren et al. \(2022a, 2022b\)](#) и другие, 45 экзогенных факторов можно разделить на 4 группы, включая факторы, связанные с товарами, факторы, связанные с облигациями, факторы, связанные с акциями, и факторы, связанные с неопределенностью. Во-первых, мы рассматриваем 8 факторов, связанных с облигациями, а именно: (i) американские корпоративные спред доходности облигаций (UCBYS); (ii) спред доходности корпоративных облигаций в евро

(ECBRS); (iii) доходность 3-месячных облигаций 3 А еврозоны (EBY3 M); (iv) ставка 3-месячных казначейских обязательств США (UTB3 M); (v) доходность 10-летних облигаций 3 А еврозоны (EBY10 M); (vi) ставка 10-летних казначейских обязательств США (UTB10 M); (vii) спред доходности

спред доходности облигаций (UGYS). Европейские факторы, связанные с облигациями, собраны в ЕЦБ, а остальные можно найти в FRED.

Во-вторых, что касается факторов, связанных с сырьевыми товарами, то, вдохновленные работой [Chevallier \(2011a\)](#) и [Ren et al. \(2022a\)](#), мы заключаем 5 энергетических ком-модификаций, а именно, (i) месячная реализованная волатильность фьючерсов на природный газ NYMEX (USGAS); (ii) фьючерсов на природный газ ICE UK (UKGAS); (iii) фьючерсов на уголь ICE Rotterdam (CRF); (iv) фьючерсов на нефть ICE Brent (BOF); (v) индекса природного газа GSCI (NGI), и 7 металлических товаров (неэнергетических), а именно, (i) реализованная волатильность на ежемесячной частоте индекса золота GSCI (GDI); (ii) индекса серебра GSCI (SLI); (iii) индекса алюминия GSCI (ALI); (iv) индекса меди GSCI (COI); (v) индекса свинца GSCI (LEI); (vi) индекс никеля GSCI (NII); и (vii) индекс цинка GSCI (ZII). Все ряды цен на сырьевые товары взяты из базы данных Wind (за исключением USGAS от EIA).<sup>4</sup> В частности, для исследования

решения записывается как

$$\mathcal{H}(\omega^T \kappa(z) + b), \quad (10)$$

где  $\omega$  - весовой вектор, а  $\kappa(z)$  представляет собой нелинейную функцию, которая отображает пространство входных данных в более высокоразмерное пространство признаков. Минимизируя структурный риск, мы можем получить оптимальную оценку коэффициентов из следующей оптимизационной задачи:

прогностическое содержание финансовой волатильности, которое включает (i) индекс All Ordinaries (AORD); (ii) индекс AEX (AEX); (iii) индекс FTSE 100 (FTSE); (v) индекс FTSE MIB (FTMIB); (vi) индекс CAC 40 (FCHI); (vii) индекс DAX (GDAXI); (viii) индекс Nikkei 225 (N225); (ix) индекс Shanghai Composite (SSEC); (x) индекс швейцарского фондового рынка (SSMI); (xi) индекс STOXX Europe 600 (SXXP); и (xii) индекс S&P 500 (INX). Мы суммируем ежедневную реализованную волатильность, собранную из библиотеки реализованной волатильности

<sup>4</sup> Учитывая различные единицы измерения некоторых предикторов, мы конвертируем иностранные валюты в евро.

<sup>3</sup> Подробный алгоритм можно найти в работе [Zhang et al. \(2019\)](#).



Таблица 1

Описание переменной.

Категория	Предикторы	Страт до конца	База данных	Расчетные методы
Факторы, связанные с облигациями	Спред доходности корпоративных облигаций США (UCBYS)	Июль 2008 -	FRED	Рассчитывается как разница между доходностью американских корпоративных облигаций с рейтингом Мудис BAA и AAA
	октябрь	2021	ЕЦБ	Рассчитывается как разница между облигациями FISE EURO BBB и AAA
	Евро спред доходности корпоративных облигаций (ECBRS)	Июль 2008 -		
	октябрь	2021		
	Доходность 3-месячных облигаций 3 А еврозоны (EBY3 M)	Июль 2008 - октябрь 2021	ЕКБ	-
	3-месячная ставка казначейства США с постоянным сроком погашения (UTB3 M)	Июль 2008 - октябрь 2021	ФРЕД	-
	Доходность 10-летних государственных облигаций 3 А еврозоны (EBY10 M)	Июль 2008 - октябрь 2021	ЕКБ	-
	Ставка постоянного погашения 10-летнего казначейства США (UTB10 M)	Июль 2008 - октябрь 2021	ФРЕД	-
	Спред доходности государственных облигаций еврозоны (EGYS)	Июль 2008 - октябрь 2021	ЕЦБ	Рассчитывается как разница между 10-летней и 1-летней доходностью евро
	Спред доходности государственных облигаций США (UGYS)	Июль 2008 -	FRED	Рассчитывается как разница между 10-летней и 1-летней
Факторы, связанные с сырьевыми товарами	октябрь	2021		доходностью в США EIA
	Природный газ на NYMEX (USGAS)	Июль 2008 - октябрь 2021	Вете	
	Фьючерсы на природный газ на ICE-UK (UKGAS)	Июль 2008 - октябрь 2021	Р	
	Фьючерсы ICE-Coal Rotterdam (CRF)	Июль 2008 - октябрь 2021	Вете	
	Нефтяные фьючерсы ICE-Brent (BOF)	Июль 2008 - октябрь 2021	Р	
	GSCI Индекс природного газа (NGI)	Июль 2008 - октябрь 2021	Ветер	
	Золотой индекс GSCI (GDI)	Июль 2008 - октябрь 2021	Вете	Рассчитывается как месячная реализованная волатильность
	Индекс серебра GSCI (SLI)	Июль 2008 - октябрь 2021	Р	
	Алюминиевый индекс GSCI (ALI)	Июль 2008 - октябрь 2021	Вете	
	Медный индекс GSCI (COI)	Июль 2008 - октябрь 2021	Р	
Факторы, связанные с акциями	Свинцовый индекс GSCI (LEI)	Июль 2008 - октябрь 2021	Вете	
	Никелевый индекс GSCI (NII)	Июль 2008 - октябрь 2021	Р	
	Цинковый индекс GSCI (ZII)	Июль 2008 - октябрь 2021	Ветер	
	Индекс All Ordinaries (AORD)	Июль 2008 - октябрь 2021	Реализованная библиотека	
	Индекс AEX (AEX)	Июль 2008 - октябрь 2021	Индекс	
	Индекс FTSE 100 (FTSE)	Июль 2008 - октябрь 2021	Индекс S&P 500 (INX)	
	Индекс FTSE MIB (FTMIB)	Июль 2008 - октябрь 2021		
	Индекс CAC 40 (FCHI)	Июль 2008 - октябрь 2021		
	Индекс DAX (GDAXI)	Июль 2008 - октябрь 2021		
	Индекс Nikkei 225 (N225)	Июль 2008 - октябрь 2021		
	Шанхайский композитный индекс (SSEC)	Июль 2008 - октябрь 2021		
	Индекс швейцарского фондового рынка (SSMI)	Июль 2008 - октябрь 2021		

Реализованная библиотека Yahoo! Finance

Рассчитывается как месячная реализованная волатильность

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Рассчитывается как сумма ежедневного rv5

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Реализованная библиотека

Глобальный инновационный индекс новой энергетики WilderHill (NEGI) Июль 2008 - октябрь 2021  
Индекс чистой энергии УайлдерХилла (CEI) Июль 2008 - октябрь 2021

Bloomberg Рассчитывается как логарифмическая разница NEGI

Bloomberg Рассчитано как

логарифмическая разница CEI Сайт CBOE

Факторы, связанные с неопределенностью

Индекс волатильности CBOE (VIX) Июль 2008 - октябрь 2021

Рассчитывается как логарифм

CBOE Индекс волатильности нефти (OVX) Июль 2008 - октябрь 2021

VIX

Индекс волатильности рынка акций США (UEMV) 2008 - октябрь 2021

Веб-сайт CBOE Рассчитано как журнал

Индекс неопределенности климатической политики (CLPU) Июль 2008 - октябрь 2021

веб-сайта OVX EPU Рассчитано как журнал

сайта UEMV EPU Рассчитано как журнал

CLPU

(продолжение на следующей странице)

Таблица 1 (продолжение)

Категория	Предикторы	Страт до конца	База данных	Расчетные методы
	Индекс неопределенности экономической политики Германии (GMEPU)	Июль 2008 - октябрь 2021	Сайт ЭПУ	Рассчитано как журнал
	Индекс неопределенности экономической политики Италии (IEPU)	Июль 2008 - октябрь 2021	сайта ГМЭПУ ЭПУ	Рассчитано как журнал сайта ИЭПУ ЭПУ
	Индекс неопределенности экономической политики Великобритании (UKERU)	Июль 2008 - октябрь 2021	как журнал сайта UKERU EPU	Рассчитано
	Индекс неопределенности экономической политики Франции (FERU)	Июль 2008 - октябрь 2021	как журнал сайта FERU EPU	Рассчитано
	Индекс неопределенности экономической политики Испании (SEPU)	Июль 2008 - октябрь 2021	как журнал сайта SEPU EPU	Рассчитано
	Индекс неопределенности экономической политики США (USEPU)	Июль 2008 - октябрь 2021	как журнал сайта USEPU EPU	Рассчитано
	Индекс неопределенности экономической политики США (USEPU)	Июль 2008 - октябрь 2021	как журнал сайта ЭПУ ЭПУ	Рассчитано
	Индекс неопределенности европейской экономической политики (EERU)		как журнал GERU	
	Индекс неопределенности глобальной экономической политики (GEPU)			

Примечания: EIA: <https://www.eia.gov/>; FRED: <https://fred.stlouisfed.org/>; ЕЦБ: <https://www.ecb.europa.eu/>; Realized Library: <https://realized.oxford-man.ox.ac.uk/>; веб-сайт CBOE: <https://www.cboe.com/>; веб-сайт EPU: <http://www.policyuncertainty.com/>.

(кроме FTMIB) <sup>5</sup> для построения ежемесячных факторов, связанных с акциями.

Наконец, учитывая влияние настроения инвесторов и рынка Мы используем 14 факторов, связанных с неопределенностью, для изучения их эффективности, включая: (i) WilderHill new energy global inno...

вационный индекс (NEGI); (ii) индекс чистой энергии WilderHill (CEI); Индекс волатильности (VIX); (v) индекс волатильности нефти CBOE (OVX); (vi) индекс волатильности американского рынка акций (UEMV); (vii) индекс неопределенности климатической политики (CLPU); (viii) индекс неопределенности экономической политики Германии (GMEPU); (ix) индекс неопределенности экономической политики Италии (IEPU); (x) индекс неопределенности экономической политики Великобритании (UKERU); (xi) индекс неопределенности экономической политики Франции (FERU); (xii) индекс неопределенности экономической политики Испании (SEPU); (xiii) индекс неопределенности экономической политики США (USEPU); (xiv) индекс неопределенности экономической политики Европы (EERU);

(xv) Индекс неопределенности глобальной экономической политики (GEPU). Все предикторы, связанные с неопределенностью, масштабируются по логарифму, чтобы устранить влияние различных величин. Детали и построение предикторов, рассматриваемых в нашем исследовании, можно найти в таблице 1.

В таблице 2 приведена описательная статистика всех предикторов и RV EUA: среднее значение, стандартное отклонение, асимметрия, эксцесс, статические показатели Тест Жарка-Бера, статика дополненного теста Дики-Фуллера. Индекс, стационарность временных рядов чрезвычайно важна в процесс лития. Представляя интерес, мы используем дополненный тест Дики-Фуллера (ADF) для проверки существования единичного корня, и результаты показывают, что все временные ряды являются стационарными.

#### 4. Результаты прогнозирования вне выборки

##### 4.1. Методы прогнозирования и оценки

Для измерения вневыборочной эффективности экзогенных драйверов мы сначала рассмотрим один из самых популярных методов - вневыборочный тест  $R^2$  Кэмпбелла и Томпсона (2008),

$$R^2_{\text{оос}} = 1 - \frac{\text{MSPE}_{\text{model}}}{\text{MSPE}_{\text{скамь}}}, \quad (12)$$

где  $\text{MSPE}_i = \frac{1}{\delta} \sum_{t=1}^{\delta} (\text{RV}_t - \text{RV}_{t_i})^2$  ( $i$  = модель, станд),  $\delta$  определяет длину периода вневыборочного окна. Очевидно, что пози- итивное значение  $R^2$  указывает на то, что расширенные модели имеют более низкий MSPE, чем эталон, что свидетельствует о более высокой эффективности прогнозирования. Для оценки существенной разницы между конкурирующими моделями и эталонами мы используем односторонний тест, статистику MSPE-adjusted, предложенную Clark и West (2007), с нулевой гипотезой о том, что MSPE эталона меньше или равен MSPE конкурирующих моделей.

Кроме того, мы также рассматриваем другую функцию потерь, среднюю ошибку прогноза абсолютного раствора (MAFE), чтобы ослабить влияние выбросов. Прибыль от RMAFE может быть определена как

$$\text{RMAFE} \text{ получает } 1 - \frac{\text{MAFE}_{\text{модель}}}{\text{MAFE}_{\text{скамь}}} \quad (13)$$

где  $\text{MAFE}_i = \frac{1}{\delta} \sum_{t=1}^{\delta} \frac{|\text{RV}_t - \text{RV}_{t_i}|}{\text{RV}_{t_i}}$  ( $i$  = модель, станд). Аналогично  $R^2_{\text{оос}}$  который позволяет оценить процентное снижение средней квадратичной ошибки прогнозирования (MSPE) конкурирующей модели ( $\text{MSPE}_{\text{model}}$ ) относительно эталона ( $\text{MSPE}_{\text{bench}}$ ). Мера  $R^2$  определяется как:

<sup>5</sup> Серия FTMIB охватывает период с июня 2009 года по октябрь 2021 года в Реализованной библиотеке. Чтобы соответствовать полному периоду выборки, мы собираем ежедневную цену закрытия FTMIB из Yahoo! Finance для построения ежемесячной реализованной волатильности.

<sup>6</sup> Индексы NEGI и CEI могут отражать глобальное развитие чистой

энергии, возобновляемой энергии и декарбонизации. Движение индекса NECI и CEI всегда сопровождается изменением выбросов углерода, что приводит к неопределенности европейского рынка выбросов углерода. Поэтому мы относим NEGI и CEI к группам неопределенности.

положительный прирост RMAFE говорит о том, что конкурирующая модель может обеспечить большую точность прогнозирования.

#### 4.2. Прогнозирование производительности

##### 4.2.1. Эффективность прогнозирования отдельных предикторов

После очистки или построения данных полный период выборки охватывает период с июля 2008 года по октябрь 2021 года, содержащий 60 месяцев. Для построения прогнозов волатильности используются рекурсивные методы прогнозирования. В качестве периода оценки мы выбрали период с июля 2008 года по декабрь 2017 года, а первый прогноз был составлен в январе 2018 года.

Чтобы выяснить, какой предиктор может в большей степени влиять на волатильность EUA (*вопрос 1*), мы сначала оценили эффективность прогнозирования отдельных предикторов. В [таблице 3](#) представлены результаты оценки прогнозирования волатильности на месяц вперед с использованием отдельных предикторов. Выяснилось несколько интересных результатов. Во-первых, мы можем заметить, что UCBYS, ECBRS, EBY3 M и EGYS дают положительные значения Roos и RMAFE, а значения остальных предикторов в панели А отрицательны. Скорректированная статистика MSPE и ее р-значения показывают, что ECBRS и EBY3 M могут значительно превосходить аналоги. Во-вторых, как показано на панели В, удивительно, но предикторы, связанные с энергетикой (кроме CRF), могут ослабить точность прогнозирования, а GDI и NII могут успешно предсказывать будущую волатильность EUA в терминах Roos и RMAFE. В-третьих, факторы, связанные с акциями, по-видимому, содержат меньше прогностической информации о волатильности EUA, поскольку расширенные модели с факторами, связанными с акциями, всегда дают отрицательные значения Roos и RMAFE. Наконец, для факторов, связанных с неопределенностью, только

Таблица 2  
Описательная статистика.

Факторы stat	Среднее значение ADF		Std.Dev	Перекоз	Куртозис	JB-stat	ADF	Факторы	Среднее значение		Std.Dev	Перекоз	Куртозис	JB-
EUA	4.899	0.943	0.168	0.188	0.877	-6.081 ***	FTSE	0.003	0.005	6.402	48.956	16,052.433 ***	-8.037 ***	
USGAS	0.021	0.021	3.623	20.130	2870.556 ***	-7.634 ***	FTMIB	0.006	0.009	5.049	32.538	7278.867 ***	-8.864 ***	
UKGAS	0.022	0.031	2.975	9.866	836.245 ***	-6.825 ***	FCHI	0.003	0.004	5.456	36.511	9106.531 ***	-7.869 ***	
CRF	0.006	0.011	3.862	18.182	2450.877 ***	-9.399 ***	GDAXI	0.003	0.004	5.706	41.584	11,656.993 ***	-7.421 ***	
BOF	0.012	0.023	5.910	41.305	11,574.107 ***	-6.114 ***	N225	0.002	0.003	5.640	40.833	11,250.390 ***	-7.428 ***	
НТИ	0.021	0.053	11.384	138.175	122,842.949 ***	-12.577 ***	SSEC	0.003	0.004	3.592	17.061	2151.661 ***	-4.840 ***	
GDI	0.003	0.003	3.021	10.466	919.510 ***	-6.315 ***	SSMI	0.002	0.004	6.941	57.990	22,283.936 ***	-9.071 ***	
SLI	0.009	0.011	3.065	11.583	1080.153 ***	-6.722 ***	SXXP	0.003	0.006	5.255	34.205	8030.010 ***	-7.715 ***	
ALI	0.004	0.003	2.514	7.909	553.234 ***	-7.880 ***	INX	0.002	0.005	5.928	41.888	11,883.143 ***	-7.083 ***	
ИСП	0.006	0.008	6.635	59.560	23,329.733 ***	-7.155 ***	NEGI	0.003	0.077	-0.868	2.482	57.487 ***	-10.218 ***	
LEI	0.008	0.010	3.880	21.466	3268.181 ***	-6.402 ***	CEI	-0.001	0.111	-0.741	2.214	44.299 ***	-11.472 ***	
НИ	0.010	0.011	5.282	36.953	9260.518 ***	-7.457 ***	VIX	2.929	0.380	0.823	0.343	18.309 ***	-4.378 ***	
ЗИ	0.007	0.007	3.515	20.049	2829.862 ***	-6.988 ***	OVX	3.571	0.374	0.663	1.644	27.641 ***	-3.595 ***	
UCBYS	-0.005	0.149	1.372	13.017	1103.786 ***	-7.330 ***	UEMV	2.967	0.343	1.101	1.893	53.266 ***	-5.948 ***	
ECBRS	0.002	0.008	-0.085	2.014	24.623 ***	-11.351 ***	CLPU	4.675	0.635	-0.304	0.623	4.562 *	-6.297 ***	
ЕВУ3 М	-0.031	0.148	-3.815	24.879	4243.544 ***	-7.674 ***	GMEPU	5.133	0.412	0.154	0.006	0.630	-5.939 ***	
УТВ3 М	-0.012	0.137	-5.624	44.111	12,987.117 ***	-9.015 ***	IEPU	4.761	0.349	-0.479	0.964	11.374 **	-6.940 ***	
ЕВУ10 М	-0.030	0.187	-0.125	0.170	0.519	-13.677 ***	UKEPU	5.560	0.463	0.261	-0.293	2.470	-4.082 ***	
УТВ10 М	-0.016	0.204	-1.148	5.444	217.394 ***	-9.495 ***	FEPU	5.445	0.340	-0.235	0.220	1.648	-6.955 ***	
EGYS	0.002	0.184	1.331	4.777	186.957 ***	-11.040 ***	SEPU	4.768	0.365	-0.185	-0.167	1.158	-7.938 ***	
UGYS	-0.001	0.144	-0.374	5.518	191.616 ***	-9.220 ***	USEPU	4.991	0.373	0.694	0.561	14.307 ***	-5.449 ***	
АОРД	0.002	0.004	5.534	36.786	9254.891 ***	-7.862 ***	EPU	5.236	0.297	-0.005	0.256	0.296	-5.140 ***	
АЕХ	0.001	0.003	8.512	86.854	49,077.650 ***	-8.860 ***	GEPU	5.059	0.364	0.521	-0.468	8.719 ***	-3.418 ***	

Примечания: Мы используем несколько статистик, включая среднее значение выборки (Mean), стандартное отклонение (Std. dev.), перекоз, эксцесс, статистику Жарка-Бера (JB-stat) и дополненный тест Дики-Фуллера (ADF). Звездочки \*\*\*, \*\* и \* означают отклонение нулевой гипотезы на 1%, 5% и 10% уровнях.

**Таблица 3**

Индивидуальный факторный анализ.

Предикторы	Roos	AMSPE	РМАФЭ (%)	Предикторы	Roos	AMSPE	РМАФЭ (%)
Панель А: Факторы, связанные с облигациями							
UCBYS	3.291	1.249	1.095	EBY10 M	-2.124	-1.220	-0.297
ECBRS	3.252	2.595 ***	3.785	UTB10 M	-1.671	-0.648	-1.328
EBY3 M	3.061	1.571 *	2.540	EGYS	1.222	0.910	3.529
UTB3 M	-2.775	-0.853	-1.325	UGYS	-0.513	-1.366	-1.278
Панель В: Факторы, связанные с сырьевыми товарами							
USGAS	-2.105	-1.319	-0.406	SLI	-0.052	0.448	0.029
UKGAS	-1.753	-1.381	-3.358	АЛИ	-1.628	-1.447	-2.538
CRF	0.145	0.275	0.185	ИСП	1.426	2.769	1.312
BOF	-6.092	-1.102	-3.324	LEI	-0.186	-1.880	-0.246
NGI	-0.278	-2.151	-0.289	НИИ	0.482	2.607 ***	0.669
GDI	7.041	1.543 *	4.432	ЗИ	-1.378	-3.107	-2.429
Панель С: Факторы, связанные с акциями							
AOPD	-0.400	-1.649	-0.270	N225	-1.449	-1.933	-2.586
AEX	-1.999	-1.756	-1.876	SSEC	-0.755	-0.508	-4.331
FTSE	-0.497	-2.136	-0.574	SSMI	-1.517	-2.312	-1.710
FTMIB	-0.619	-1.019	-0.393	SXXP	-0.632	-1.890	-0.531
FCHI	-0.134	-0.686	0.106	INX	-0.321	-0.542	-0.095
GDAXI	-2.308	-2.350	-2.953				
Панель D: Факторы, связанные с неопределенностью							
NEGI	7.626	2.593 ***	25.307	IEPU	-4.294	-1.172	-2.643
CEI	2.059	1.661 **	8.173	UKEPU	-4.268	-2.349	-5.859
VIX	-1.702	-0.947	-1.708	FEPU	-1.331	-1.764	-1.957
OVX	-2.415	-1.202	-1.384	SEPU	-0.930	-2.174	-1.014
UEMV	-2.068	-1.145	-1.981	USEPU	-7.401	-1.299	-6.709
CLPU	-1.590	-1.437	-1.269	EEPU	-5.952	-2.008	-7.721
GMEPU	-11.107	-1.237	-12.686	GEPU	-17.483	-2.066	-21.388

**Примечания:** В таблице представлена оценка вневыборочной эффективности моделей на основе вневыборочного теста  $R^2$  и RMAFE для индивидуального факторного анализа. Первый вневыборочный прогноз начинается в январе 2018 года, а окно прогнозирования охватывает 46 месяцев.

**Таблица 4**

Эффективность прогнозирования диффузионных методов и комбинаций прогнозов.

Модель	Roos	AMSPE	РМАФЭ (%)	Модель	Roos	AMSPE	РМАФЭ (%)
Панель А: Факторы, связанные с облигациями							
PCA	-1.496	-0.196	-2.425	MCF	0.233	0.395	-0.333
PLS	1.304	0.973	-0.411	MECF	0.573	1.031	-0.183
SPCA	-0.071	-0.068	-0.059	TMCF	0.209	0.385	-0.262
Панель В: Факторы, связанные с сырьевыми товарами							
PCA	0.398	0.788	0.167	MCF	0.665	0.567	0.188
PLS	2.949	0.536	-2.735	MECF	-0.102	-0.603	-0.077
SPCA	3.943	0.779	0.025	TMCF	0.334	0.456	0.079
Панель С: Факторы, связанные с акциями							
PCA	-0.362	-1.278	-0.333	MCF	-0.214	-0.629	-0.175
PLS	1.897	1.909 **	1.865	MECF	-0.135	-1.004	-0.133
SPCA	0.247	0.366	-0.255	TMCF	-0.275	-1.106	-0.246
Панель D: Факторы, связанные с неопределенностью							
PCA	-2.005	-0.131	-0.673	MCF	-0.507	-0.312	0.244
PLS	-1.914	0.163	1.225	MECF	-0.867	-1.009	-0.333
SPCA	-2.653	-0.306	-1.063	TMCF	-0.599	-0.425	-0.078
Панель E: Все факторы							
PCA	-0.107	-0.276	0.060	MCF	0.090	0.254	0.026
PLS	-0.507	0.648	-0.042	MECF	-0.090	-0.800	-0.021
SPCA	-2.888	-0.400	-1.200	TMCF	0.028	0.117	-0.043

**Примечания:** В таблице представлены показатели вне выборки для модели диффузионного индекса и комбинированного метода прогнозирования. Первый вневыборочный прогноз начинается в январе 2018 года, а окно прогнозирования охватывает 46 месяцев.



Таблица 5  
Прогнозная эффективность метода контролируемого обучения.

Модель	Roos	AMSPE	RMAFE (%)
Панель А:			
Эластичная сеть	10.002	2.127 **	6.365
ELN-Bond			
ELN-Commodity	9.300	2.149 **	4.409
ELN-Stock	11.107	2.334 ***	7.300
ELN-Uncertainty	13.908	2.322 **	6.945
ELN-All	8.016	1.769 **	5.557
Панель В:			
LASSO LASSO-Bond	10.667	2.003 **	6.728
LASSO-Commodity	13.504	2.262 **	7.659
LASSO-Equity	12.882	2.167 **	7.365
LASSO-неопределенность	14.132	2.350 ***	7.152
LASSO-All	13.269	2.242 **	7.176
Панель С:			
SVR SVR-Bond	14.581	2.888 ***	10.017
SVR-Commodity	8.807	2.839 ***	7.599
SVR-Equity	13.230	3.366 ***	9.933
SVR-Uncertainty	10.809	3.302 ***	5.547
SVR-All	17.859	3.391 ***	9.964

**Примечания:** В таблице представлены вневыборочные показатели для метода контролируемого обучения. ELN-*i* (*i* ∈ {Bond, Commodity, Equity, Uncertainty, All}) представляет собой прогнозы волатильности, созданные на основе модели ELN с *i*-реализованными прогнозами. предикторы. Например, ELN-B обозначает модель ELN с предикторами, связанными с облигациями. Первый прогноз вне выборки начинается в январе 2018 года, а окно прогнозирования охватывает 46 месяцев.

NEGI и CEI могут давать значительные и положительные значения Roos и RMAFE, что свидетельствует о том, что эти два индекса могут определять волатильность фьючерсов на EUA.

В целом, эффективность прогнозирования отдельных предикторов указывает на то, что 6 из 45 предикторов могут значительно предсказать волатильность EUA, включая ECBRS, EBY3 M, GDI, NII, NEGI и CEI. ECBRS и EBY3 M являются предикторами, связанными с облигациями; как обсуждалось ранее, доходность корпоративных или государственных облигаций может отражать экономические условия в европейской зоне, что, в свою очередь, влияет на выбросы углерода. NEGI и CEI могут определять волатильность EUA, поскольку развитие новых или чистых видов энергии (таких как солнечная, ветровая и водородная энергия) может снизить использование ископаемых видов топлива (таких как сырая нефть и уголь) для достижения цели декарбонизации. Кроме того, остальные 39 предикторов демонстрируют ограниченную эффективность прогнозирования, что может быть вызвано следующими причинами: i) подобно результатам предыдущих исследований, например, [Rapach et al. \(2010\)](#) и [Zhang et al. \(2019\)](#), индивидуальный предиктор едва ли консис-... постоянно сохраняет мощную прогностическую способность в долгосрочной перспективе или

во время изменения рыночных условий из-за неопределенности; ii) превосходные показатели прогнозирования предикторов станут разочаровывающими и со временем теряют эмпирическую поддержку ([Goyal и др., 2021](#)).

4.2.2. Всеобъемлющая информация и эффективность прогнозирования  
Для решения вопроса 2 (Как инвесторы и исследователи используют информацию, извлеченную из различных предикторов на практике?) и преодоления неопределенности модели, мы далее

утверждают, что комплексная информация, извлеченная из различных исследований, демонстрирует мощную предсказательную способность для волатильности или доходности активов по следующим причинам: i) худшая эффективность прогнозирования отдельных предикторов приводит к разочаровывающим результатам диффузионных моделей и комбинированных прогнозов. Однако, по сравнению с результатами анализа отдельных предикторов, отрицательное значение комплексного показателя приближается к нулю (особенно для факторов, связанных с неопределенностью), что говорит о том, что комплексная информация несколько улучшает точность прогноза по сравнению с отдельными предикторами. ii) Индекс диффузии опирается на статистический главный компонент различных предикторов; однако вес каждого предиктора не определяется важностью или влиянием предиктора на волатильность EUA. Хотя метод SPCA требует масштабирования каждого предиктора по его коэффициенту, некоторые предикторы могут оказывать нелинейное влияние на волатильность EUA.

4.2.3. Супервизорское обучение и эффективность прогнозирования

Далее мы исследуем, может ли метод контролируемого обучения помочь в прогнозировании волатильности EUA, чтобы ответить на вопрос 3 (Помогает ли метод контролируемого обучения повысить точность прогнозирования волатильности EUA)? Вневыборочная производительность ELN, LASSO и SVR показана в [таблице 5](#). Очевидно, что три метода контролируемого обучения, рассмотренные в данном исследовании, могут последовательно давать положительные значения Roos и RMAFE, что говорит о том, что методы контролируемого обучения могут значительно улучшить прогноз волатильности EUA по сравнению с конкурирующими моделями в нашем исследовании. Мы можем наблюдать несколько выводов. Во-первых, как показано на панели А, модель ELN с предикторами, связанными с облигациями, факторами, связанными с товарами, факторами, связанными с акциями, факторами, связанными с неопределенностью, и всеми факторами может снизить MSPE на 10,002%, 9,300%, 11,107%, 13,908% и 8,016% соответственно, что говорит о том, что модель ELN может значительно превзойти эталон. Результаты модели LASSO аналогичны результатам ELN. Примечательно, что связанные с неопределенностью предикторы в рамках методов отбора переменных (LASSO и ELN) могут генерировать наибольшее значение Roos, что означает, что связанные с неопределенностью факторы содержат больше прогностического содержания для прогнозирования волатильности EUA, чем другие группы, даже все предикторы. Во-вторых, в отличие от методов выбора переменных, регрессия опорного вектора со всеми предикторами может значительно снизить MSPE от 8,807% до 17,859%. Для модели SVR учет всех предикторов может дать более высокое значение, чем конкурирующие модели.

Впоследствии, чтобы изучить, являются ли наши выводы устойчивыми с течением времени, мы рассматриваем кумулятивную квадратичную ошибку прогноза (CSFE) для построения графика оценки прогноза, которая определяется как

$$CSFE = \sum_{i=1}^T (RV_i - \hat{RV}_{i,t}^{i, модель})^2 \quad (14)$$

где *i* (ELN, LASSO и SVR), а  $\hat{RV}_{i,t}^{i, модель}$  представляет собой прогнозы рассмотрели комплексную информацию, извлеченную из различных предикторов, включенных в наше исследование.<sup>7</sup> В [таблице 4](#) представлены результаты оценки комбинированного прогноза (MCF, MECF и TMCF) и моделей индекса диффузии (PCA,

PLS и SPCA). К нашему удивлению, мы обнаружили, что модель PLS с факторами, связанными с акциями, может значительно превзойти эталон и индивидуальные предикторы, а остальные модели практически не улучшают точность прогнозирования волатильности EUA. Наши выводы отличаются от результатов предыдущих исследований, которые

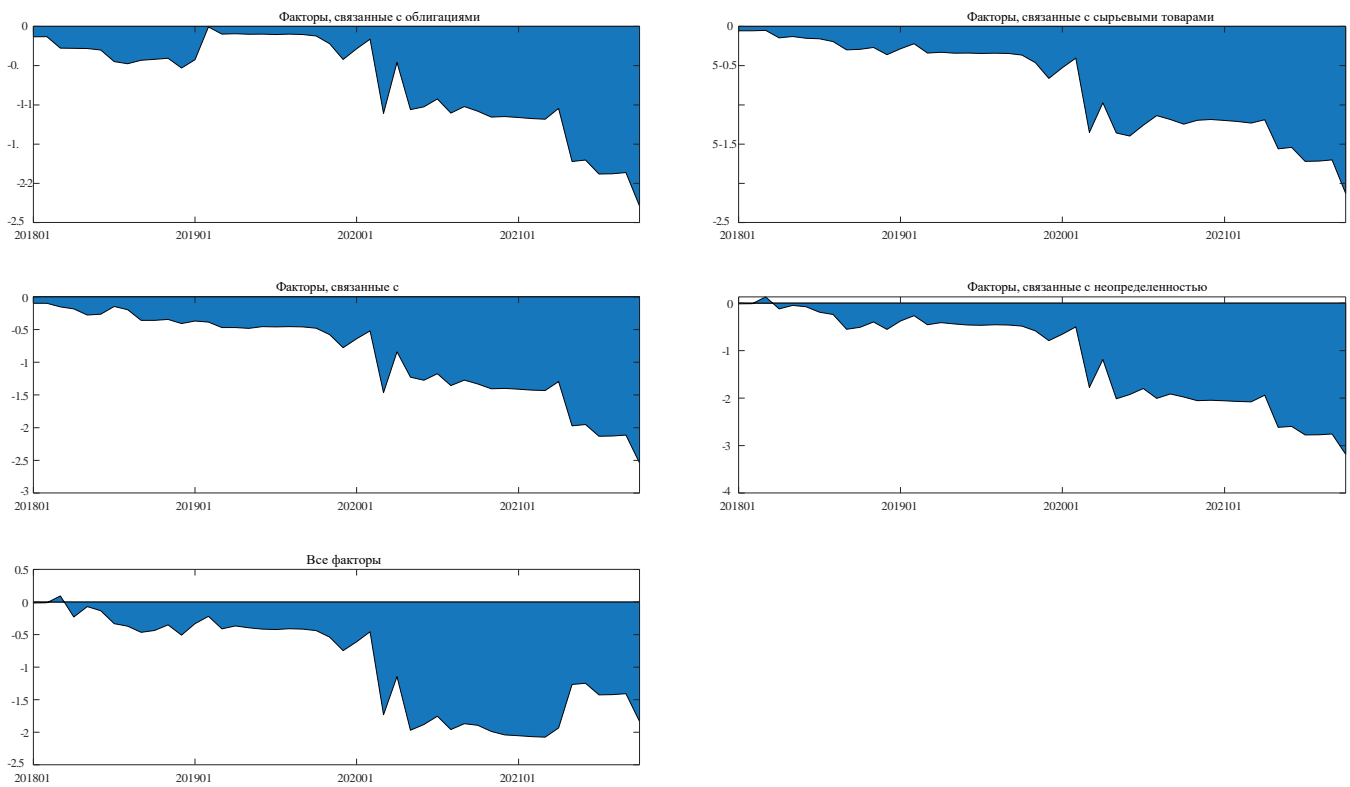
<sup>7</sup> Для обеспечения сопоставимости мы рассматриваем точно такой же метод прогнозирования (рекурсивный метод) и окно прогнозирования (последние 46 месяцев) с индивидуальным факторным анализом. Кроме того, следуя Neely et al. (2014), мы определяем  $K$  (количество индексов диффузии, используемых в прогнозных регрессиях) по скорректированному  $R^2$ .

генерированный моделью  $i$  в месяце  $t$ . Очевидно, что отрицательное значение

CSFE показывает, что конкурирующая модель может превзойти эталон.

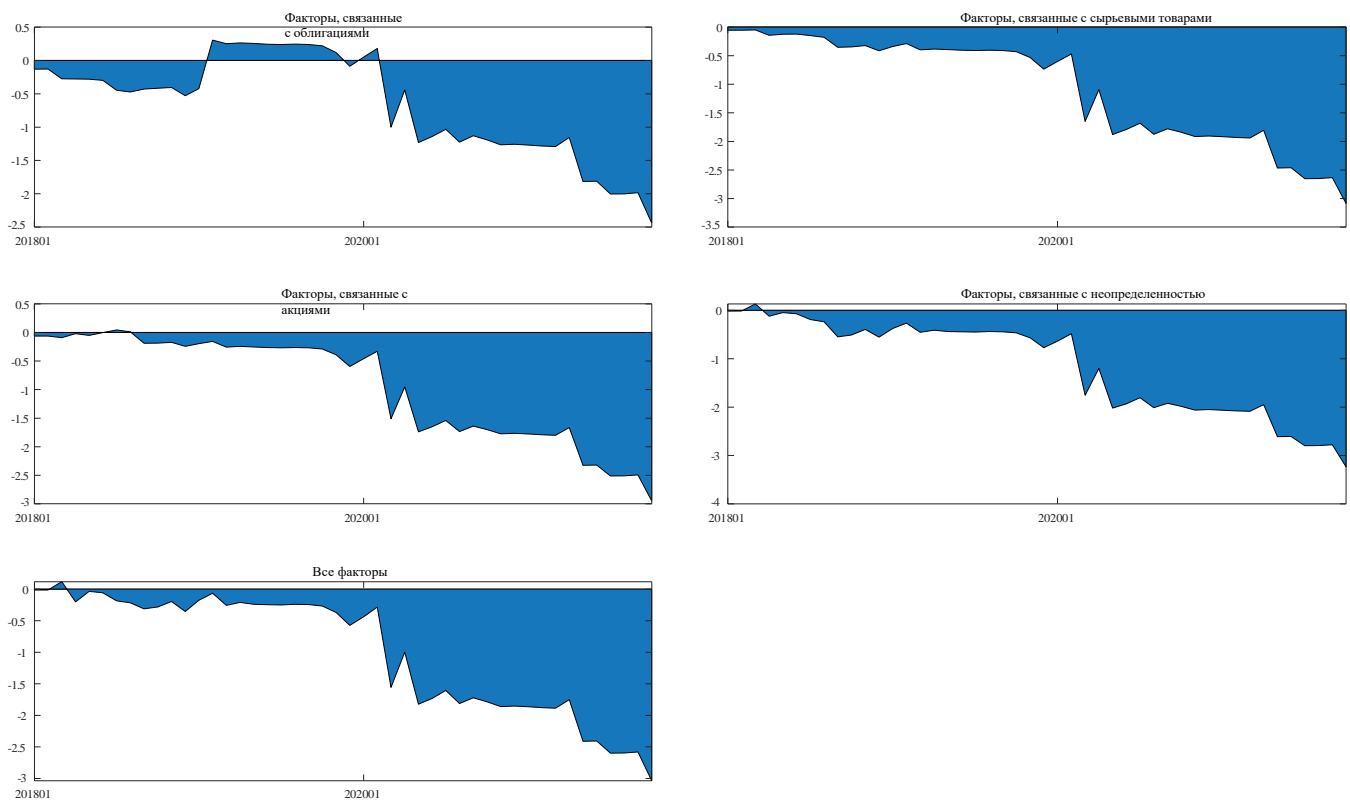
На рис. 1-3 показаны CSFE для ELN, LASSO и SVR. Здесь необходимо подчеркнуть некоторые интересные выводы. Во-первых, заметная тенденция к снижению появляется примерно в январе 2020 года для моделей выбора переменных (ELN и LASSO) с факторами, связанными с облигациями, факторами, связанными с товарами, факторами, связанными с акциями, и факторами, связанными с неопределенностью. Кроме того, модели ELN и LASSO могут генерировать меньший CSFE по сравнению с аналогами на основе величины оси  $Y$ , если учитывать только факторы, связанные с неопределенностью. Во-вторых, график факторов, связанных с облигациями, товарами и акциями, показывает положительное значение CSFE (или близкое к 0) с января 2019 года по октябрь 2019 года, что говорит о слабой эффективности прогнозирования в этот период. Модель SVR со всеми факторами может превзойти аналоги. В-третьих, модели контролируемого обучения (LASSO, ELN и SVR) показывают хорошие результаты в конце периода вне выборки (после июля 2020 года).

Более высокая производительность методов контролируемого обучения, вероятно, объясняется следующими причинами. Во-первых, с математической точки зрения, выбор переменных (ELN и LASSO) имеет тенденцию быть более смещенным, чем OLS, что в дальнейшем



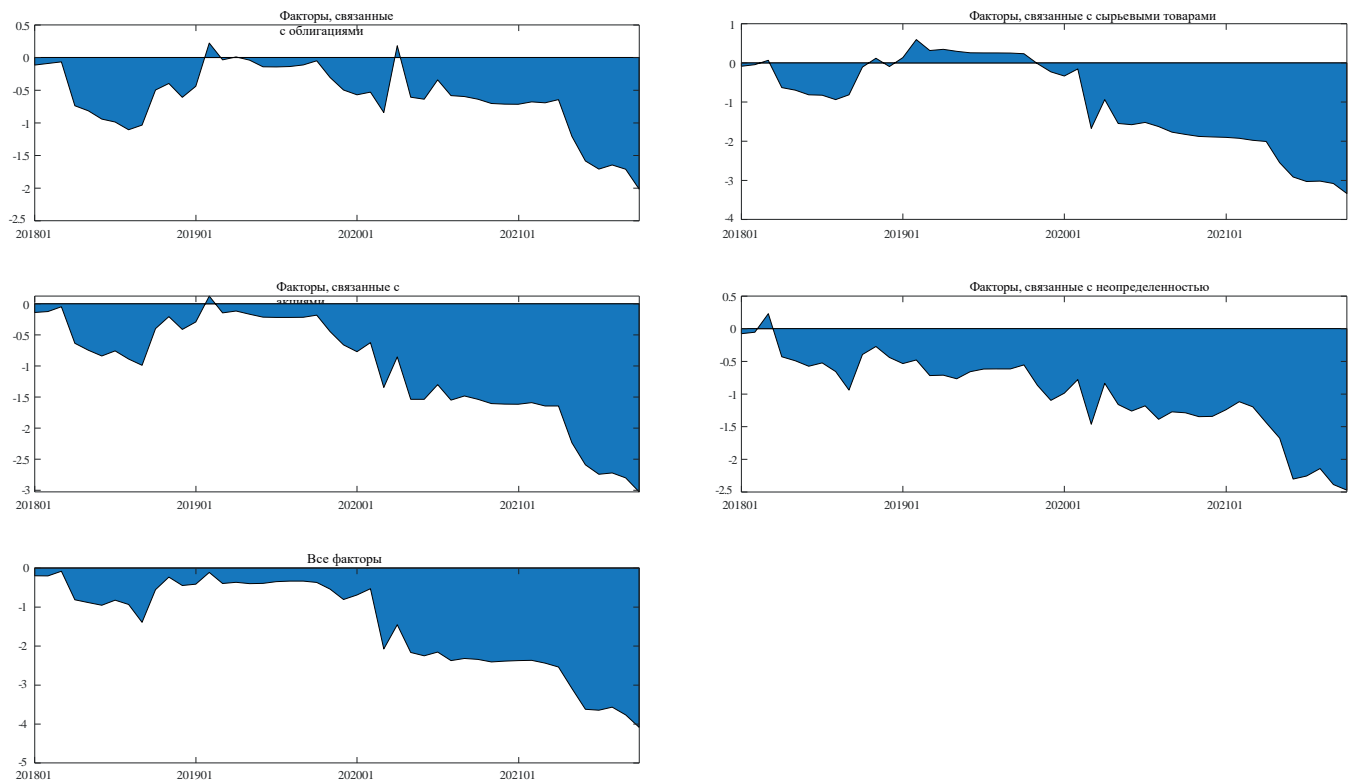
**Рис. 1.** CSFE моделей типа упругой сети.

Примечания: На этом рисунке показан CSFE регрессии ELN.




**Рис. 2.** CSFE модели типа LASSO.

Примечания: На этом рисунке показан CSFE регрессии ELN.




**Рис. 3.** CSFE модели типа SVR.

Примечания: На этом рисунке показан CSFE регрессии ELN.




**Рис. 4.** Частоты выбора факторов в ELN.

Примечания: На этом рисунке представлены частоты выбора факторов из ELN.



**Рис. 5.** Частоты выбора факторов в LASSO.

Примечания: На этом рисунке показаны частоты выбора факторов по данным LASSO.



**Рис. 6.** Значимость факторов, сформированная SVR-моделью.

Примечания: На этом рисунке показана значимость факторов, сформированная методом аддитивного объяснения Шэпли (SHAP), предложенным Лундберггом и Ли (2017).

уменьшают дисперсию, что приводит к повышению эффективности прогнозирования (Pla-kandaras and Ji, 2022). Более того, в отличие от индекса диффузии, грубо извлеченного из различных предикторов, на основе всеобъемлющей информации, выбор переменных может установить коэффициенты бесполезных или неважных переменных на 0. Однако мы также можем заметить, что эффективность прогнозирования при выборе переменных не определяется количеством предикторов. Во-вторых, как популярный метод машинного обучения, SVR обладает огромными преимуществами с точки зрения малой выборки, нелинейной характеристики и регрессии высокой размерности, что приводит к превосходной эффективности прогнозирования.

4.3. Интерпретируемость модели

Поскольку модель неопределенна и условия меняются, анализ индивидуальных предикторов, скорее всего, будет неубедителен для участников рынка и в...  
весторов. Чтобы убедительно ответить на *вопрос 1*, данный подраздел далее выяснит, какой фактор может более эффективно определять волатильность EUA, используя частоты выбора переменных и важности факторов для интерпретации модели.

Более конкретно, ELN и LASSO могут выбрать ценные переменные и установить коэффициенты бесполезных переменных в 0. Что касается методов выбора переменных, мы перечисляем коэффициенты каждой переменной за период вне выборки, чтобы рассчитать частоты выбора для каждого переменной. На рис. 4 и 5 показаны частоты выбора из ELN и LASSO, соответственно. Выяснилось несколько интересных результатов. Во-первых, GDI, SSEC, NEGI, ECBRS, EBY3 M, EGYS, UCBYS, ZII, INX, UTB10 M и SLI являются 11 предикторами, наиболее часто выбираемыми ELN; однако LASSO предпочитает выбирать следующие факторы: NEGI, UCBYS, ECBRS, EGYS, SSEC, EBY3 M, UTB10 M, GDI и UTB3 M. Во-вторых, мы можем наблюдать, что из ELN и LASSO одновременно выбираются 5 факторов, связанных с облигациями, с высокой частотой отбора, то есть ECBRS, EBY3 M, EGYS, UCBYS и UTB10 M, что говорит о том, что факторы, связанные с облигациями, могут сильно влиять на волатильность EUA. Наконец, GDI и NEGI являются предикторы, наиболее часто выбираемые ELN и LASSO, которые предоставляют эмпирические доказательства того, что GDI и NEGI играют чрезвычайно важную роль в прогнозировании волатильности EUA.

Разница в алгоритме между выбором переменных и SVR, т.е. линейные и нелинейные, приводит к различным методам интерпретируемости модели. Для определения важности каждого предиктора мы используем метод аддитивного объяснения Шэпли (SHAP), предложенный Лундбергом и Ли (2017), который опирается на теоретико-игровые оптимальные значения Шэпли. В частности, SHAP позволяет получить доступ к вкладу каждого предиктора в прогнозы волатильности EUA. Большее значение SHAP указывает на неоспоримую важность предикторов. На рис. 6 показано среднее значение SHAP за период вне выборки. Примечательно, что мы можем наблюдать очевидную разницу между отбором переменных и SVR. Во-первых, результаты важности факторов показывают, что NEGI, CEL, GEPU, ECBRS, FEPU, GDI, IEPU, EBY10 M, EEPU, EGYS и USEPU - это 11 самых важных факторов. 7 факторов, связанных с неопределенностью, вероятно, будут доминировать над волатильностью EUA

прогнозирования с помощью модели SVR. Во-вторых, NEGI, ECBRS, GDI и EGYS играют значительно большую роль в прогнозировании волатильности EUA с точки зрения результатов частот отбора переменных и важности факторов.

4.4. Портфельное упражнение

По сравнению со статистической эффективностью прогнозирования экзогенных факторов, участники рынка и политики уделяют больше внимания экономической выгоде модели прогнозирования. Для измерения портфельного эксперимента мы используем систему реализованной полезности Боллерслева и др.

(2018), который опирается только на прогнозы волатильности (RV). В частности, средневариационный инвестор распределяет  $\omega_t$  своего актива на рисковый актив с  $r_{t+1}$  и  $(1 - \omega_t)$  на безрисковый актив с  $r^f$ . Ожидаемая полезность с постоянным условным коэффициентом Шарпа может быть записана как

$$U(\omega) = \frac{1}{2} \left( \frac{E_t(RV_{t+1}) - r^f}{\sigma_t(RV_{t+1})} \right)^2 \gamma, \quad (15)$$

где  $\gamma$  обозначает относительное неприятие риска инвестором,  $E_t(RV_{t+1}) = Vqr(r^e)$ , где  $r^e$  - избыточная доходность,  $r - r^f$ , и постоянный коэффициент Шарпа,  $SR \equiv E_t(r) / \sigma_t(RV_{t+1})$ . Чтобы получить оптимальный портфель, инвестор распределяет свое богатство  $x_t^* = E_t(r_{t+1}) / (\gamma E_t(RV_{t+1}))$  на рисковый актив, или, альтернативно,  $\omega^* = \frac{SR}{1 + SR^2 / \gamma}$ , где  $SR / \gamma$  обозначает оптимальный коэффициент Шарпа.

целевой риск. Следовательно, ожидаемая полезность оптимального целевого портфеля может быть определена как

$$U(\omega^*) = \frac{1}{2} \frac{SR^2}{\gamma} W_t = \frac{1}{2} \times SR \times \frac{SR}{\gamma} W_t, \quad (16)$$

где 1/2 означает половину ожидаемого дохода, не потерянную из-за бесполезности риск, а  $SR \times \frac{SR}{\gamma}$  - ожидаемая избыточная доходность. Однако на практике инвестор не может наблюдать  $E_t(RV_{t+1})$ . В результате прогноз волатильности  $(RV_{t+1})$  заменяет  $E_t(RV_{t+1})$ , в результате чего средняя ожидаемая полезность составляет

$$U_{t+1} = \frac{1}{2} \left( \frac{RV_{t+1} - r^f}{\sigma_t(RV_{t+1})} \right)^2 \gamma, \quad (17)$$

Модель	Реализованная полезность (%)				
	Облигация	Товар	Капитал	Неопределенность	Все
Скамейка	3.023	3.023	3.023	3.023	3.023
PCA	2.984	3.028	3.023	3.062	3.022
SPCA	2.997	3.185	3.055	2.981	3.050
PLS	3.020	3.118	3.061	3.038	3.033
Средний	3.012	3.045	3.027	3.022	3.028
Медиана	3.021	3.021	3.023	3.024	3.022
TMC	3.013	3.033	3.023	3.029	3.028
ELN	3.159	3.176	3.195	3.228	3.142
LASSO	3.175	3.217	3.221	3.229	3.205
SVR	3.184	3.048	3.140	3.130	3.255

Примечания: В таблице представлены экономические выгоды от прогнозов волатильности, полученных на основе всех регрессий.

Таблица 6  
Экономические выгоды.



В примере Bollerslev et al. (2018), мы установили годовой коэффициент Шарпа и коэффициент относительного неприятия риска как  $SR = 0,4$  и  $\gamma = 2$ , соответственно. Следовательно,  $U(x, *) = 4\% W_t$ , что означает, что инвестор готов заплатить 4 % своего богатства, чтобы получить доступ к  $\omega_t$  \* портфель рискованного актива вместо того, чтобы просто инвестировать в безрисковый актив. Другими словами, модель риска, которая идеально предсказывает RV, обеспечивает реализованную полезность  $8\% - 4\% = 4\%$ .

В таблице 6 представлены результаты реализованной полезности для прогнозов волатильности полученных в результате различных регрессий. Столбцы 2-6 таблицы 6 представляют среднюю полезность модели прогнозирования с учетом факторов, связанных с облигациями, товарами, акциями, неопределенностью и всеми факторами, соответственно. Как показано в таблице 6, можно сделать несколько выводов. Во-первых, модели PCA, SPCA и PLS с факторами, связанными с товаром, могут генерировать полезность 3,028%, 3,185% и 3,118%, соответственно, по сравнению с эталоном 3,023%, что говорит о том, что индекс диффузии, полученный из факторов, связанных с товаром, может немного увеличить экономическую выгоду. Во-вторых, реализованная полезность, полученная с помощью комбинированных методов прогнозирования (MCF, MECF и TCMF), близка к эталонной, что означает, что комбинированный метод прогнозирования едва ли улучшает экономические выгоды. Наконец, интерес представляет то, что методы контролируемого обучения могут генерировать значительно более высокую реализованную полезность, чем аналоги. В частности, реализованная полезность методов выбора переменных (ELN и LASSO) с факторами, связанными с неопределенностью, и SVR со всеми предикторами составляет 3,228%, 3,229% и 3,255%, соответственно. Результаты портфельного упражнения предоставляют эмпирические доказательства того, что методы выбора переменных (ELN и LASSO) с факторами, связанными с неопределенностью, и SVR со всеми предикторами могут достичь более высоких экономических выгод, чем аналогичные методы на практике.

Таблица 7

Результаты альтернативного окна прогнозирования.

Модель	Облигация		Товарные		Акции		Неопределенность		Все	
	Roos	РМАФЭ (%)	Roos	РМАФЭ (%)	Roos	РМАФЭ (%)	Roos	РМАФЭ (%)	Roos	РМАФЭ (%)
PCA	0.081	-0.848	0.104	0.229	-0.315	-0.374	-1.985	-2.164	-0.203	-0.092
SPCA	1.687	1.057	1.381	-0.925	1.044	0.837	-1.121	-0.663	-0.766	-1.866
PLS	-0.094	-0.032	2.256	1.325	0.261	-0.888	-2.128	-2.160	-2.258	-2.334
Среднее	0.255	-0.080	0.217	0.192	-0.202	-0.297	-0.594	-0.515	-0.037	-0.195
Медиана	0.501	-0.045	-0.116	-0.031	-0.202	-0.204	-1.266	-0.942	-0.146	-0.086
TMC	0.408	0.046	0.087	0.114	-0.232	-0.299	-0.539	-0.666	-0.025	-0.200
ELN	6.348 **	3.510	7.761 **	3.797	6.567 **	3.648	7.970 **	4.794	6.247 **	4.440
LASSO	6.697 **	3.714	9.909 ***	5.489	8.322 ***	4.223	8.477 **	5.164	8.256 **	4.863
SVR	9.074 **	8.090	9.872 ***	8.749	10.328 ***	8.664	11.963 ***	7.495	19.186 ***	12.044

**Примечания:** В таблице представлены вневыборочные показатели для модели диффузионного индекса, комбинированного метода прогнозирования и метода контролируемого обучения. Первый вневыборочный прогноз начинается в январе 2016 года, а окно прогнозирования охватывает 70 месяцев.

Таблица 8

Результаты DM-теста.

Модель	Облигация		Товарные		Акции		Неопределенность		Все	
	DM1	DM2	DM1	DM2	DM1	DM2	DM1	DM2	DM1	DM2
PCA	-0.600	-1.257	1.121	0.660	-1.780	-1.181	-1.492	-0.286	-0.579	0.235
SPCA	0.883	-0.142	-0.059	-0.758	1.152	2.187 **	-0.027	0.372	-0.052	-0.011
PLS	0.519	-0.168	0.923	0.014	-0.930	-0.254	-1.455	-0.435	-1.526	-0.495
Среднее	0.620	-0.452	0.586	0.439	-1.436	-0.603	-0.365	0.291	0.136	0.096
Медиана	1.223	-0.345	-0.103	-0.518	-1.016	-1.029	-1.583	-0.593	-0.948	-0.204
TMC	0.680	-0.437	0.576	0.290	-1.546	-1.031	-0.849	-0.098	-0.232	-0.171
ELN	1.566 *	1.484 *	1.727 **	1.370 *	1.626 *	1.948 **	1.796 **	1.377 *	1.097	1.094
LASSO	1.433 *	1.378 *	1.817 **	1.746 **	1.600 *	1.686 **	1.835 **	1.418 *	1.755 **	1.423 *
SVR	1.777 **	1.121	2.115 **	1.537 *	2.283 **	1.595 *	1.868 **	0.851	2.115 **	1.364 *

**Примечания:** В таблице представлены результаты теста DM для модели диффузионного индекса, комбинированного метода прогнозирования и метода контролируемого обучения. Первый вневыборочный прогноз начинается в январе 2018 года, а окно прогнозирования охватывает 46 месяцев.

#### 4.5. Проверка надежности

##### 4.5.1. Альтернативный период вне выборки

Эффективность прогнозирования чувствительна к продолжительности периода вне выборки. В этом подразделе рассматривается другое окно для подтверждения наших эмпирических выводов. Мы расширяем предыдущее окно прогнозирования, и первый прогноз генерируется в январе 2016 года и содержит 70 месяцев. Вневыборочная производительность альтернативного вневыборочного периода

показано в [таблице 7](#). Отбор переменных (ELN и LASSO) и SVR модель могут дать значимое и положительное значение Roos и RMAFE

(%), что свидетельствует о том, что методы контролируемого обучения могут последовательно

успешно прогнозируют волатильность EUA. Эмпирические результаты подтверждают, что наши выводы устойчивы к окну прогнозирования.

##### 4.5.2. Альтернативный метод оценки

Другой популярный метод оценки, тест Диболда-Мариано (DM) [Диболда и Мариано \(1995\)](#), широко используется для исследования парных различий между эталонными и конкурирующими моделями. Для оценки статистики DM мы рассматриваем следующие две функции потерь,

с поправкой на гетероскедастичность среднееквдрат ошибка (HMSE) и средняя абсолютная ошибка с поправкой на гетероскедастичность (HMAE), определяемая как

$$HMSE = \delta^{-1} \sum_{t=1}^{\delta} (1 - \hat{R}V_t / RV_t)^2, \quad (18)$$

$$HMAE = \delta^{-1} \sum_{t=1}^{\delta} |1 - \hat{R}V_t / RV_t|, \quad (19)$$

где  $\delta$  - длина периода вне выборки. Статистику DM можно выразить как

$$DM_i = \frac{\bar{d}}{\sqrt{\text{Var}(d)}} \quad (20)$$

где  $d = \frac{1}{\delta} \sum_{t=1}^{\delta} d_t$ ,  $d_t$  обозначает дифференциал HMSE и HMAE,

$\text{Var}(d)$  - дисперсия  $d_t$ , а  $i = (\text{HMSE}, \text{HMAE})$ . Нулевая гипотеза теста DM нет разницы между эталонной и конкурирующими моделями.

В [таблице 8](#) представлены результаты теста DM. Мы можем наблюдать, что

Таблица 9

Результаты нескольких горизонтов прогнозирования.

Регрессии	$H = 3$		$H = 6$		$H = 12$	
	Roos	AMSPE	Roos	AMSPE	Roos	AMSPE
MCF	-0.775	-2.265	-0.987	-2.524	-1.290	-2.470
MECF	3.312**	2.260	3.188**	1.967	0.028	1.130
TMCF	-0.589	0.904	-2.058	0.463	-6.142	-0.656
PCA	0.196	0.752	-0.013	0.068	-0.697	-1.352

<i>J. Mag и др.</i>	0.304	1.009	0.137	0.383	-0.550	0.000
SPCA	0.206	0.725	0.004	0.114	-0.684	-1.175
ELN	16.120	2.644 ***	19.360	2.700 ***	31.683	3.563 ***
LASSO	14.615	2.597 ***	19.622	2.873 ***	28.431	3.502 ***
SVR	37.353	3.335 ***	46.624	3.498 ***	59.158	3.868 ***

**Примечания:** В данной таблице представлены результаты многоступенчатой оценки на опережение.

**Таблица 10**

Результаты предикторов, связанных с сельским хозяйством.

Регрессии	Roos	AMSPE	Регрессии	Roos	AMSPE
Панель А: предикторы, связанные с сельским хозяйством					
PCA	-0.131	-0.239	MCF	0.101	0.350
PLS	-0.359	-0.429	MECF	-5.531	-0.229
SPCA	-0.396	-0.492	TMCF	0.101	0.350
ELN	10.554	2.237 **	LASSO	12.263	2.394 ***
SVR	12.622	3.013 ***			
Панель В: Все предикторы					
PCA	-0.230	-1.041	MCF	0.001	0.046
PLS	-0.172	0.786	MECF	-0.136	-1.535
SPCA	-0.230	-1.041	TMCF	-0.014	0.006
ELN	12.577	2.264 **	LASSO	8.759	1.696 **
SVR	18.179	3.222 ***			

**Примечания:** В данной таблице представлены результаты оценки предикторов, связанных с сельским хозяйством. Первый вневыборочный прогноз начинается в январе 2018 года, а окно прогнозирования охватывает 46 месяцев.

Статистика DM1 выбора переменных (ELN и LASSO) и SVR положительна при функции потерь HMSE (кроме ELN со всеми предикторами), что говорит о том, что методы контролируемого обучения могут значительно отклонить нулевую гипотезу. Кроме того, методы контролируемого обучения (ELN, LASSO и SVR) также могут отклонить нулевую гипотезу при функции потерь HMAE (за исключением SVR с факторами, связанными с облигациями, SVR с факторами, связанными с неопределенностью, и ELN со всеми факторами). Результаты DM согласуются с результатами вневыборочного теста  $R^2$  и выигрышами RMAFE, что говорит о том, что супервизированные методы обучения могут повысить точность прогнозирования волатильности EUA.

#### 4.5.3. Множественные горизонты прогнозирования

В нашем исследовании далее изучается эффективность прогнозных регрессий для 3-месячного, 6-месячного и 12-месячного горизонтов прогнозирования, поскольку участники рынка концентрируются не только на краткосрочных, но и на средне- и долгосрочных показателях.<sup>8</sup> Теоретически, для прогнозирования на несколько шагов вперед, мы заменяем левую часть прогнозной регрессии

$$\text{регрессии с } RV_{t+1,h} = \frac{1}{h} \sum_{i=1}^h RV_{t+i}.$$

В таблице 9 представлены оценки

результаты прогнозирования волатильности на несколько горизонтов вперед. Очевидно, что мы можем заметить, что методы контролируемого обучения, включая ELN, LASSO и SVR, могут получить положительные и значимые значения Roos для горизонтов на 3 месяца вперед, 6 месяцев вперед и 12 месяцев вперед, что говорит о том, что методы контролируемого обучения могут последовательно улучшать точность прогнозирования волатильности EUA.

#### 4.5.4. Увеличение числа предикторов

В этом подразделе мы рассмотрим 10 экзогенных предикторов, связанных с сельским хозяйством, чтобы подтвердить превосходную эффективность методов контролируемого обучения.<sup>9</sup> В частности, по примеру Тан и др. (2022), в наше исследование включены следующие предикторы, связанные с

сельским хозяйством: индекс какао GSCI (GCOC), индекс кофе GSCI (GCOF), индекс кукурузы GSCI (GCOR), индекс хлопка GSCI (GCOT), индекс соевых бобов GSCI (GCSY), индекс сахара GSCI (GCSU), индекс пшеницы GSCI (GCWH), индекс комбикормов

и 10 факторов, связанных с сельским хозяйством. Очевидно, что ELN, LASSO и SVR могут дать положительные и значимые значения Roos, что еще раз подтверждает наши предыдущие выводы о том, что методы контролируемого обучения могут успешно прогнозировать волатильность EUA. В целом, наши результаты устойчивы к количеству экзогенных факторов.

## 5. Резюме и заключительные замечания

Данное исследование в основном проливает свет на роль различных экзогенных факторов в прогнозировании волатильности EUA, используя комбинированные методы прогнозирования, модели индекса диффузии и методы контролируемого обучения. Мы рассматриваем 45 экзогенных факторов, которые можно разделить на следующие классы: 8 факторов, связанных с облигациями, 12 факторов, связанных с товарами, 11 факторов, связанных с акциями, и 14 факторов, связанных с неопределенностью. Целью данного исследования является решение следующих вопросов. *Вопросы 1 (Q1): Какой экзогенный предиктор может в большей степени влиять на волатильность EUA? Вопрос 2 (Q2): Как инвесторы и исследователи используют информацию, извлеченную из различных предикторов, на практике? Вопросы 3 (Q3): Помогает ли метод контролируемого обучения повысить точность прогнозирования волатильности EUA?*

Здесь можно выделить несколько интересных выводов. Во-первых, для решения вопроса Q1 мы сначала оцениваем эффективность прогнозирования отдельных факторов. Эмпирические результаты показывают, что ECBRS, EBY3 M, NII, GDI, NEGI и CEI могут сильно влиять на волатильность EUA. Во-вторых, с точки зрения проблемы чрезмерной подгонки, мы далее рассматриваем модели диффузионного индекса (PCA, PLS и SPCA) и комбинированные методы прогнозирования (MCF, MECF и TMCF), которые могут включать в себя комплексную информацию, извлеченную из 45 экзогенных факторов, для решения вопроса Q2. Результаты показывают, что модели индекса диффузии и комбинированные методы прогнозирования практически не повышают точность прогнозирования волатильности EUA, поскольку лишь немногие отдельные факторы могут успешно прогнозировать волатильность EUA. В-третьих, для ответа на вопрос Q3 мы дополнительно изучили эффективность прогнозирования с помощью методов контролируемого обучения (ELN, LASSO и SVR). Наши результаты показывают, что выбор переменных (ELN и LASSO) и SVR превосходят по эффективности прогнозирование волатильности EUA. Более того, чтобы выяснить, какие экзогенные переменные могут влиять на волатильность EUA (Q1), мы используем частоты выбора переменных и важность факторов для интерпретации модели. Мы обнаружили, что NEGI, ECBRS, GDI и EGYS играют значительную роль.

GSCI (GCFD), индекс постных свиней GSCI (GCLH) и индекс живого скота GSCI (GCLC). Аналогичным образом, мы рассчитываем реализованную волатильность на ежемесячной частоте для этих 10 предикторов, связанных с сельским хозяйством. В таблице 10 представлены результаты оценки предикторов, связанных с сельским хозяйством. Результаты панели А показывают, что диффузионные модели и комбинированные методы не могут повысить точность прогнозирования волатильности, в то время как методы контролируемого обучения могут значительно превзойти аналоги. Кроме того, на панели В показаны результаты оценки всех предикторов, включая 8, связанных с облигациями, 12, связанных с товарами, 11, связанных с акциями, 14, связанных с неопределенностью.

<sup>8</sup> Мы благодарны анонимному рецензенту за это конструктивное предложение.

<sup>9</sup> Мы благодарны анонимному рецензенту за это конструктивное предложение.

4. Итоги выбора переменных и важности факторов. Наконец, мы оцениваем дополнительные реализованные выгоды комбинированного метода прогнозирования, модели диффузионного индекса и метода контролируемого обучения для участников рынка и политиков. Наши результаты убедительно свидетельствуют о том, что метод контролируемого обучения может достичь более высоких экологических выгод, чем конкурирующие модели на практике.

Вышеприведенные выводы имеют важное значение для участников европейского углеродного рынка. Инвесторы или эмиссионные компании могут получить статистически значимое улучшение прогнозирования волатильности EUA при использовании различных экзогенных факторов, таких как индекс глобальных инноваций в новой энергетике Wilder Hill (NEGI), спред доходности еврокорпоративных облигаций (ECBRS), индекс золота GSCI (GDI) и спред доходности государственных облигаций еврозоны (EGYS), что означает, что им следует уделять больше внимания движению цен на европейском рынке облигаций, золота и чистой энергии. В связи с этим наши выводы важны для ученых, а также для управляющих портфелями и рисками в их стремлении более точно прогнозировать волатильность EUA. Наш анализ прогнозов также касается политиков и центральных банков, которые все больше интересуются волатильностью EUA, поскольку некоторые из них рассматривают возможность запуска собственных рынков выбросов углерода. В будущих исследованиях можно изучить каналы передачи волатильности от финансовых рынков (таких как рынки ископаемых энергоносителей, чистой энергии и акций) к углеродным рынкам.

#### **Декларация о конкурирующих интересах**

Авторы заявляют, что у них нет известных конкурирующих финансовых интересов или личных отношений, которые могли бы повлиять на работу, представленную в данной статье.

## Благодарности

Авторы благодарны редактору и анонимным рецензентам за содержательные замечания, которые значительно улучшили статью. Работа выполнена при поддержке Фонда естественных наук Китая [72071162, 72271204], Фонда естественных наук провинции Сычуань [2022NSFC0917].

## Ссылки

- Аатола, П., Олликайнен, М., Топпинен, А., 2013. Определение цены на рынке EU ETS: теория и эконометрический анализ с учетом фундаментальных показателей рынка. *Energy Econ.* 36, 380-395.
- Alberola, E., Chevallier, J., Ch'ez, B., 2008. Ценообразующие факторы и структурные разрывы в европейских ценах на углерод 2005-2007 гг. *Энергетическая политика* 36 (2), 787-797.
- Авад, М., Ханна, Р., 2015. Вспомогательная векторная регрессия. In: *Эффективные обучающие машины*. Apress, Berkeley, CA, pp. 67-80.
- Бенц, Е., Трюк, С., 2009. Моделирование динамики цен на квоты на выбросы CO<sub>2</sub>. *Energy Econ.* 31 (1), 4-15.
- Бишоп, К.М., Насрабади, Н.М., 2006. Распознавание образов и машинное обучение, том 4. Springer, New York, p. 738. No. 4.
- Bollerslev, T., Hood, B., Huss, J., Pedersen, L.H., 2018. Риск повсюду: моделирование и управление волатильностью. *Rev. Financ. Stud.* 31 (7), 2729-2773.
- Бен, С.Дж., Чо, Х., 2013. Прогнозирование волатильности углеродных фьючерсов с помощью GARCH-моделей с волатильностью энергоносителей. *Energy Econ.* 40, 207-221.
- Кэмпбелл, Дж.И., Томпсон, С.Б., 2008. Прогнозирование избыточной доходности акций вне выборки: может ли что-нибудь побить историческое среднее? *Rev. Financ. Stud.* 21 (4), 1509-1531.
- Шевалье, Ж., 2009. Углеродные фьючерсы и макроэкономические факторы риска: взгляд из EU ETS. *Energy Econ.* 31 (4), 614-625.
- Шевалье, Ж., 2010. Прогнозирование волатильности цен на углерод с использованием факторных моделей. *Экон. Bull.* 30 (2), 1642-1660.
- Шевалье, Ж., 2011a. Модель взаимодействия цен на углерод с макроэкономической и энергетической динамикой. *Energy Econ.* 33 (6), 1295-1312.
- Шевалье, Ж., 2011b. Обнаружение нестабильности в волатильности цен на углерод. *Energy Econ.* 33 (1), 99-110.
- Шевалье, Ж., 2011c. Макроэкономика, финансы, товары: взаимодействие с углеродными рынками в модели с большим количеством данных. *Экон. Model.* 28 (1-2), 557-567.
- Шевалье, Ж., Севи, Б., 2011. О реализованной волатильности фьючерсного контракта ECX на выбросы CO<sub>2</sub> за 2008 год: распределение, динамика и прогнозирование. *Ann. Finance* 7 (1), 1-29.
- Кристиансен, А.К., Арванитакис, А., Танген, К., Хасселкниппе, Х., 2005. Детерминанты цен в схеме торговли выбросами ЕС. *Clim. Pol.* 5 (1), 15-30.
- Кларк, Т.Е., Вест, К.Д., 2007. Приблизительно нормальные тесты на одинаковую предсказательную точность во вложенных моделях. *J. Econ.* 138 (1), 291-311.
- Корси, Ф., 2009. Простая приближенная модель реализованной волатильности с длинной памятью. *J. Financ. Econ.* 7 (2), 174-196.
- Dai, P.F., Xiong, X., Huynh, T.L.D., Wang, J., 2022. Влияние неопределенности экономической политики на волатильность европейского углеродного рынка. *J. Commod. Mark.* 26, 100208.
- Диболд, Ф.Х., Мариано, Р.С., 1995. Сравнение точности прогнозирования. *J. Bus. Econ. Stat.* 13 (3).
- Дутта, А., 2018. Моделирование и прогнозирование волатильности рынка углеродных выбросов: роль выбросов, скачков, изменяющихся во времени, и риска цен на нефть. *J. Clean. Prod.* 172, 2773-2781.
- Дутта, А., Бури, Э., Нур, М.Х., 2018. Связь доходности и волатильности между ценами акций компаний, выбрасывающих CO<sub>2</sub>, и чистой энергии. *Energy* 164, 803-810.
- Fan, Y., Jia, J.J., Wang, X., Xu, J.H., 2017. Какие корректировки политики в EU ETS действительно повлияли на цены на углерод? *Энергетическая политика* 103, 145-164.
- Feng, Z.H., Zou, L.L., Wei, Y.M., 2011. Волатильность цен на углерод: Доказательства из EU ETS. *Appl. Energy* 88 (3), 590-598.
- Ghoddusi, N., Creamer, G.G., Rafizadeh, N., 2019. Машинное обучение в энергетической экономике и финансах: обзор. *Energy Econ.* 81, 709-727.
- Гойал, А., Уэлч, И., Зафиров, А., 2021. A Comprehensive Look at the Empirical Performance of Equity Premium Prediction II. Доступно по адресу SSRN 3929119.
- Хуанг, Д., Цзян, Ф., Ту, Ж., Чжоу, Г., 2015. Выравнивание настроений инвесторов: мощный предиктор доходности акций. *Rev. Financ. Stud.* 28 (3), 791-837.
- Хуанг, Д., Цзян, Ф., Ли, К., Тонг, Г., Чжоу, Г., 2021. Масштабный PCA: новый подход к уменьшению размерности. *Manag. Sci.* <https://doi.org/10.1287/mnsc.2021.4020>.
- Liu, J., Zhang, Z., Yan, L., Wen, F., 2021. Прогнозирование волатильности фьючерсов EUA с неопределенностью экономической политики с помощью модели GARCH-MIDAS. *Fin. Innov.* 7 (1), 1-19.
- Лундберг, С.М., Ли, С.И., 2017. Единый подход к интерпретации прогнозов моделей. *Adv. Neural Inf. Proces. Syst.* 30.
- Мансанет-Баталлер, М., Пардо, А., Валор, Е., 2007. Цены на CO<sub>2</sub>, энергия и погода. *Energy J.* 28 (3).
- Нили, К.Дж., Рапач, Д.Е., Ту, Ж., Чжоу, Г., 2014. Прогнозирование премии за риск акций: роль технических индикаторов. *Manag. Sci.* 60 (7), 1772-1791.
- Paoella, M.S., Taschini, L., 2008. Эконометрический анализ цен на квоты на выбросы. *J. Bank. Financ.* 32 (10), 2022-2032.
- Paye, B.S., 2012. 'D'eja' a vol': прогнозные регрессии для совокупной волатильности фондового рынка с использованием макроэкономических переменных. *J. Financ. Econ.* 106 (3), 527-546.
- Плакандарас, В., Цици, К., 2022. Внутренние разложения в прогнозировании золота. *J. Commod. Mark.* <https://doi.org/10.1016/j.jcomm.2022.100245>, 100245.
- Рапач, Д.Е., Штраус, Дж.К., Чжоу, Г., 2010. Прогнозирование премии по акциям вне выборки: комбинированные прогнозы и связь с реальной экономикой. *Rev. Financ. Stud.* 23 (2), 821-862.
- Ren, X., Duan, K., Tao, L., Shi, Y., Yan, C., 2022a. Прогнозирование цен на углерод в квантилях. *Energy Econ.* 108, 105862.
- Ren, X., Li, Y., Wen, F., Lu, Z., 2022b. Взаимосвязь между рынком углерода и рынком "зеленых" облигаций: свидетельства на основе метода вейвлет-квантилей на квантилях. *Technol. Forecasting. Soc. Chang.* 179, 121611.
- Тан, Х., Сиричанд, К., Вивинан, А., Ванг, Х., 2020. Насколько углеродный рынок связан с энергетическими и финансовыми рынками? Систематический анализ перегибов и динамики. *Energy Econ.* 90, 104870.
- Тан, Х., Сиричанд, К., Вивинан, А., Ванг, Х., 2021. Прогнозирование доходности европейского углерода с использованием методов уменьшения размерности: товарные и финансовые показатели. *Int. J. Forecast.* <https://doi.org/10.1016/j.ijforecast.2021.07.005>. Forthcoming.
- Тибиширани, Р., 1996. Сокращение и отбор регрессии с помощью лассо. *J. R. Stat. Soc. Ser. B Methodol.* 58 (1), 267-288.
- Ванник, В., 1999. Природа теории статистического обучения. Springer Science & Business Media.
- Ванг, Й., Гуо, З., 2018. Динамический перегиб между углеродным и энергетическим рынками: новые данные. *Energy* 149, 24-33.
- Ван, Ж., Ма, Ф., Бури, Э., Чжун, Ж., 2022. Волатильность чистой энергии и природного газа, индексы неопределенности и глобальные экономические условия. *Energy Econ.* 108, 105904.
- Вэнь, Ф., Чжао, Х., Чжао, Л., Инь, Х., 2022. Что определяет динамику цен на углерод в Китае? *Int. Rev. Financ. Anal.* 79, 101999.
- Ye, S., Dai, P.F., Nguyen, H.T., Huynh, N.Q.A., 2021. Является ли кросс-корреляция цены углеродного рынка ЕС с неопределенностью политики действительно существующей? Многомасштабная мультифрактальная перспектива. *J. Environ. Manag.* 298, 113490.
- Zhang, Y.J., Sun, Y.F., 2016. Динамический переток волатильности между европейским рынком торговли углеродными квотами и рынком ископаемых энергоносителей. *J. Clean. Prod.* 112, 2654-2663.
- Чжан, Й.Ж., Чжан, Ж.Л., 2018. Прогнозирование волатильности рынка сырой нефти: новый гибридный метод. *J. Forecast.* 37 (8), 781-789.
- Zhang, Y., Ma, F., Wang, Y., 2019. Прогнозирование цен на сырую нефть с большим набором предикторов: может ли LASSO выбрать мощные предикторы? *J. Empir. Financ.* 54, 97-117.
- Zhang, Y., Wahab, M.I.M., Wang, Y., 2022. Прогнозирование волатильности рынка сырой нефти с использованием отбора переменных и общего фактора. *Int. J. Forecast.* <https://doi.org/10.1016/j.ijforecast.2021.12.013>.
- Zhu, B., Ye, S., Wang, P., He, K., Zhang, T., Wei, Y.M., 2018. Новая многомасштабная нелинейная парадигма ансамблевого опирания для прогнозирования цен на углерод. *Energy Econ.* 70, 143-157.
- Zou, H., Hastie, T., 2005. Регуляризация и выбор переменных с помощью эластичной сети. *J. R. Stat. Soc. Ser. B* 67 (2), 301-320.